

# Optimalizáló algoritmusok

Baran Ágnes

Előadás

A tananyag elkészítését az EFOP-3.4.3-16-2016-00021 számú projekt támogatta. A projekt az Európai Unió támogatásával, az Európai Szociális Alap társfinanszírozásával valósult meg.

# Tartalom I

1 Példák optimalizációs feladatokra

2 Jelölések, alapfogalmak

3 Optimalizációs feladatok

- Jelölések, alapfogalmak
- Kvadratikus függvények
- A lokális szélsőérték feltételei
- Konvex függvények
- Alapvető stratégiák

4 Vonalmenti keresések

- Gradiens módszer
- Newton-módszer
- Kvázi-Newton módszerek

5 Feltételes optimalizálás

6 Megbízhatósági tartomány módszerek

7 Konjugált gradiens módszer

- Lineáris eset

# Tartalom II

- Nemlineáris eset

## 8 Nagyméretű feladatok

## 9 Deriváltmentes módszerek

- Nelder-Mead algoritmus


## 10 Legkisebb négyzetes feladatok

- Lineáris legkisebb négyzetek
- Nemlineáris legkisebb négyzetek
  - Gauss-Newton módszer
  - Levenberg-Marquardt módszer
- Legkisebb négyzetes módszerek alkalmazásai

# Példák optimalizációs feladatokra

## Egy egyszerű példa


A parttól 10 km-re fekvő sziget áramellátását szeretnénk biztosítani egy olyan áramellátó központból, amely közvetlenül a parton helyezkedik el, 20 km-re a partnak a szigethez legközelebbi pontjától. Ha 250 ezer Ft-ba kerül 1 km víz alatti vezeték elhelyezése, és 100 ezerbe 1 km vezeték telepítése a szárazföldön, akkor határozzuk meg a minimális kölcségű útvonalat.



A költségfüggvény (az árat ezer Ft-ban számolva):

$$f(x) = 250 \cdot \sqrt{10^2 + x^2} + 100 \cdot (20 - x)$$

# Példák optimalizációs feladatokra



Az

$$f(x) = 250 \cdot \sqrt{10^2 + x^2} + 100 \cdot (20 - x)$$

függvény.  $x_{opt} = 4.3644$ ,  $f(x_{opt}) = 4291.3$

# Példák optimalizációs feladatokra

## Még egy egyszerű példa

Az  $1000 \text{ cm}^3$  térfogatú téglatestek közül melyiknek a felszíne lesz minimális?

A célfüggvény (a téglatest éleinek hosszát  $x_1, x_2, x_3$ -mal jelölve):

$$f(x_1, x_2, x_3) = 2x_1x_2 + 2x_1x_3 + 2x_2x_3$$


Korlátrozó feltétel:

$$x_1x_2x_3 = 1000$$

A korlátrozó feltétel eliminálható:

$$f(x_1, x_2) = 2x_1x_2 + \frac{2000}{x_2} + \frac{2000}{x_1}$$

# Példák optimalizációs feladatokra



Az

$$f(x_1, x_2) = 2x_1x_2 + \frac{2000}{x_2} + \frac{2000}{x_1}$$

függvény.  $x_{opt} = (10, 10)$ ,  $f(x_{opt}) = 600$

# Példák optimalizációs feladatokra

## Egy elhelyezési probléma (Fermat-Weber)

Adott egy bolthálózat  $m$  üzletének elhelyezkedése. Helyezzük el az áruraktárat úgy, hogy az üzletektől vett távolságainak összege minimális legyen.

Jelölje  $a_i \in \mathbb{R}^2$  az  $i$ -edik üzlet helykoordinátáit,  $x \in \mathbb{R}^2$  a raktár helye.


A célfüggvény:

$$f(x) = \sum_{i=1}^m \|a_i - x\|$$

A feladat másik változata: adottak a  $w_1, \dots, w_m$  súlyok, a minimalizálandó függvény:


$$f(x) = \sum_{i=1}^m w_i \|a_i - x\|$$

# Egy elhelyezési probléma



A  $(2.5, 0)$ ,  $(0, 0)$ ,  $(4, 3)$ ,  $(1, 4)$  pontokhoz és a  $w_1 = w_2 = w_3 = w_4 = 1$  súlyokhoz tartozó célfüggvény.

# Egy elhelyezési probléma



A  $(2.5, 0)$ ,  $(0, 0)$ ,  $(4, 3)$ ,  $(1, 4)$  pontokhoz és a  $w_1 = w_2 = w_3 = w_4 = 1$  súlyokhoz tartozó megoldás a célfüggvény szintvonalaival.

# Példák optimalizációs feladatokra

## Egy elhelyezési feladat (1-kör probléma)

Egy téli üdülőövezetben a mentőhelikopter bázisállomását úgy szeretnénk elhelyezni, hogy az  $n$  adott síközponttól mért legnagyobb távolsága minimális legyen.


Meg kell találnunk azt a  $c$  középpontú  $r$  sugarú kört, mely lefedi az adott  $n$  pontot, és a sugara minimális.

Ha az  $i$ -edik síközpont koordinátája  $a_i \in \mathbb{R}^2$ , akkor a célfüggvény:

$$F(c) = \max_i \|a_i - c\|$$

A keresett kör középpontja a minimumhely, sugara a minimumérték.

# Egy elhelyezési probléma



A  $(2.5, 0)$ ,  $(0, 0)$ ,  $(4, 3)$ ,  $(1, 4)$  pontokhoz tartozó kör.

# Példák optimalizációs feladatokra



# Példák optimalizációs feladatokra

## Minimális felület

Adott egy  $\Omega \subset \mathbb{R}^2$  tartomány,  $\Gamma$  peremmel. Legyen  $r : \Gamma \rightarrow \mathbb{R}$  adott függvény. Olyan  $q : \bar{\Omega} \rightarrow \mathbb{R}$  függvényt keresünk, mely a peremen egybeesik  $r$ -rel, és amelynek a gráfja minimális felszínű.

Tekintsük  $\bar{\Omega}$  egy reguláris triangularizációját:

$$\bar{\Omega} \approx \bigcup_{k=1}^m T_k$$

A triangularizáció belső csúcsponjtai legyenek

$$x^1, \dots, x^n \in \Omega,$$

a perempontjai

$$x^{n+1}, \dots, x^{n+\ell} \in \Gamma$$

A  $q$  függvényt egy olyan folytonos  $q_T : \bigcup_{k=1}^m T_k \rightarrow \mathbb{R}$  függvénnnyel közelítjük, mely minden  $T_k$  háromszög felett lineáris.

Legyen  $z_i = q_T(x^i)$ ,  $i = 1, \dots, n + \ell$ .

Ha a  $T_k$  háromszög csúcsai  $x^{a_k}, x^{b_k}, x^{c_k}$ , akkor a  $T_k$  fölötti gráf felszíne:

$$A_k(z) = \frac{1}{2} \left\| \begin{pmatrix} x^{b_k} - x^{a_k} \\ z_{b_k} - z_{a_k} \end{pmatrix} \times \begin{pmatrix} x^{c_k} - x^{a_k} \\ z_{c_k} - z_{a_k} \end{pmatrix} \right\|$$

### A feladat:


$$\min_{y \in \mathbb{R}^{n+\ell}} \sum_{k=1}^m A_k(z)$$

a

$$z_i = r(x_i), \quad i = n + 1, \dots, n + \ell$$

feltételek mellett.


# Minimális felület



$$\Omega = (0, 1)^2 \text{ és } r(x, y) = \frac{1}{2} - |y - \frac{1}{2}|$$

10 × 11 rácspont


# Minimális felület



$$\Omega = (0, 1)^2 \text{ és } r(x, y) = \frac{1}{2} - |y - \frac{1}{2}|$$

15 × 15 rácspont


# Minimális felület



$$\Omega = (0, 1)^2 \text{ és } r(x, y) = \sqrt{\frac{1}{4} - \left(y - \frac{1}{2}\right)^2}$$

$10 \times 11$  rácspont

# Minimális felület



$$\Omega = (0, 1)^2 \text{ és } r(x, y) = \sqrt{\frac{1}{4} - \left(y - \frac{1}{2}\right)^2}$$

15 × 15 rácspont

# Példák optimalizációs feladatokra

## Modell illesztése (regresszió)

Adottak a  $(t_i, f_i)$ ,  $i = 1, \dots, m$ , megfigyelések, ezekre szeretnénk adott  $F(t, x)$  alakú modellt illeszteni, ahol  $x = (x_1, \dots, x_n)$  ismeretlen paraméterek és  $m > n$ .

A

$$J(x) = \sum_{i=1}^m (F(t_i, x) - f_i)^2$$

függvényt minimalizáljuk, ahol  $J : \mathbb{R}^n \rightarrow \mathbb{R}$

Ha  $F$  a paraméterek lineáris függvénye, akkor lineáris legkisebb négyzetes feladat, ellenkező esetben nemlineáris legkisebb négyzetes feladat.

# Példák optimalizációs feladatokra

## Helymeghatározás GPS-sel

Az ismert  $(x_i, y_i, z_i)$  koordinátájú  $S_i$  műholdak által kibocsátott adott terjedési sebességű hullámok mérésének segítségével kell a vevőkészülék  $(x, y, z)$  koordinátáját meghatározni.

Az  $S_i$  műhold a fedélzeti atomórája segítségével digitális kódot állít elő, ezzel modulálja a kibocsátott hullámot. A vevő a saját órája szerint előállítja a kódot, és a kettőt összehasonlítva meghatározza az eltelt  $\Delta t_i$  időt, majd ebből az  $R_i = \Delta t_i \cdot c$  távolságot.

Ebből a vevő  $(x, y, z)$  koordinátáira

$$(x - x_i)^2 + (y - y_i)^2 + (z - z_i)^2 = (\Delta t_i \cdot c)^2$$

3 ismeretlen  $\rightarrow$  3 műhold

## Helymeghatározás GPS-sel

Mivel a vevő órája általában nincs szinkronban a műholdak óráival, ezért a  $\Delta t_i$  értéke pontatlan ( $1 \mu s$  időeltérés kb 300 m eltérés a távolságban...)

Tehát a  $t_0$  időkülönbség van az atomórák és a vevő által mutatott idők között. Ekkor az előző egyenlet helyett:

$$(x - x_i)^2 + (y - y_i)^2 + (z - z_i)^2 = ((\Delta t_i + t_0) \cdot c)^2$$

4 ismeretlen  $(x, y, z, t_0) \rightarrow 4$  műhold szükséges

Nemlineáris legkisebb négyzetes feladat, további mérések (műholdak) tovább csökkenthetik a hibát.

# Példák optimalizációs feladatokra

## Hatóanyag koncentráció

Egy szájon át bevett gyógyszer esetén a szervezetben  $t$  idő után az  $x(t)$  hatóanyag koncentrációt az ú.n. Bateman-függvény írja le

$$x(t) = \begin{cases} C_0 \frac{\lambda_1}{\lambda_2 - \lambda_1} (e^{-\lambda_1 t} - e^{-\lambda_2 t}) & \text{ha } \lambda_1 \neq \lambda_2, \\ C_0 \lambda_1 e^{-\lambda_1 t} & \text{ha } \lambda_1 = \lambda_2 \end{cases}$$


ahol  $\lambda_1$ ,  $\lambda_2$  és  $C_0$  paraméterek. Pácienseknél adott időpontokban megmérték a hatóanyag koncentrációját a vérben, ezek alapján becsüljük meg a paramétereket.

Ha adottak a  $(t_i, x_i)$ ,  $i = 1, \dots, m$  mérések, akkor a célfüggvény:

$$f(C_0, \lambda_1, \lambda_2) = \sum_{i=1}^m |x(t_i) - x_i|^2$$

(Nemlineáris regresszió)

# Hatóanyag koncentráció



Az illesztett Bateman-függvény egy konkrét adatsor esetén.

# Példák optimalizációs feladatokra

## Image deblurring

Adott egy zajos kép és valami információ a zajról: pl. a fotóalany vagy a fotós elmozdulásából származik a zaj. Próbáljuk meg helyreállítani a képet.



## Image deblurring (motion blur)

Adott a torzítást leíró  $D$  mátrix, és a torzított képet tartalmazó  $b$  vektor. Keressük azt az  $x$  vektort (az eredeti kép), melyre  $b = Dx$ . Ezt legkisebb négyzetek módszerével megoldva még mindig zajos lehet az eredmény, így egy  $\lambda\|Lx\|^2$  regularizációs tagot is hozzáveszünk a célfüggvényhez:

$$f(x) = \|Dx - b\|^2 + \lambda\|Lx\|^2$$




# Példák optimalizációs feladatokra

## Neurális hálózatok

Adottak az  $x^1, \dots, x^M$  input vektorok (képek, szövegek, stb.) és a megfelelő  $d_1, \dots, d_M$  címek. Úgy szeretnénk meghatározni a neurális hálózat (MLP, CNN, stb) súlyait, hogy a veszteségfüggvény minimális értéket vegyen fel, pl.

$$F(w) = \frac{1}{2M} \sum_{i=1}^M (d_i - y_i)^2,$$

ahol  $y_i$  a hálózat által  $x^i$ -re adott kimenet.



# Példák optimalizációs feladatokra

## Portfólió optimalizálás

Egy megadott összegből szeretnénk  $n$  féle részvény közül vásárolni úgy, hogy a várható hozam egy megadott  $\varrho$  korlát fölött legyen, ugyanakkor a kockázat minimális legyen.

Tehet az  $i$ -edik részvény hozama egy  $m_i$  várható értékű valószínűségi változó, és legyen  $C$  a hozamok kovarianciamátrixa.

Az  $x = (x_1, \dots, x_n)$  portfólió kockázata az

$$\frac{1}{2}x^T C x$$

függvénnyel mérhető, a korlátozó feltételek:

$$\sum_{i=1}^n m_i x_i \geq \varrho, \quad \sum_{i=1}^n x_i = 1, \quad x \geq 0$$

# Jelölések, definíciók

Az  $x \in \mathbb{R}^n$  vektor alatt az

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad x_i \in \mathbb{R}$$

oszlopvektort értjük.

## Euklideszi vektornorma

$$\|x\| = \left( \sum_{i=1}^n x_i^2 \right)^{1/2}, \quad x \in \mathbb{R}^n$$

## Megjegyzés

$$\|x\| = \sqrt{x^T x}$$

## Definíció (Pozitív szemidefinit, pozitív definit mátrix)

Az  $A \in \mathbb{R}^{n \times n}$  mátrix pozitív szemidefinit, ha

$$x^T A x \geq 0 \quad \text{ minden } x \in \mathbb{R}^n \quad \text{esetén,}$$

pozitív definit, ha

$$x^T A x > 0 \quad \text{ minden } x \in \mathbb{R}^n \quad x \neq 0, \quad \text{esetén.}$$

## Állítás

Ha  $A \in \mathbb{R}^{n \times n}$  szimmetrikus, akkor a következő állítások ekvivalensek:

- $A$  pozitív definit
- Az  $A$  összes bal felső főminora pozitív
- Létezik az  $A = LL^T$  Cholesky-felbontás, reguláris  $L$  mátrixszal
- Az  $A$  összes sajátértéke pozitív

## Definíció (Negatív szemidefinit, negatív defintit, indefinit mátrix)

Az  $A \in \mathbb{R}^{n \times n}$  mátrix negatív szemidefinit, ha

$$x^T A x \leq 0 \quad \text{ minden } x \in \mathbb{R}^n \quad \text{esetén,}$$

negatív definit, ha

$$x^T A x < 0 \quad \text{ minden } x \in \mathbb{R}^n \quad x \neq 0, \quad \text{esetén.}$$

Az  $A$  mátrix indefinit, ha nem pozitív definit, pozitív szemidefinit, negatív definit, negatív szemidefinit.

## Tétel

A szimmetrikus  $A \in \mathbb{R}^{n \times n}$  mátrix pontosan akkor

- pozitív definit, ha minden bal felső főminora pozitív
- negatív definit, ha a bal felső főminorai váltakozva negatívak és pozitívak (az első negatív).

## Állítás

Egy szimmetrikus  $A \in \mathbb{R}^{2 \times 2}$  mátrix pontosan akkor

- pozitív definit, ha  $a_{11} > 0$  és  $\det(A) > 0$ ,
- negatív definit, ha  $a_{11} < 0$  és  $\det(A) > 0$ ,
- indefinit, ha  $\det(A) < 0$ .

# Optimalizációs feladatok

Adott egy  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  függvény, keresett

$$\min_x f(x),$$

amikor

$$c_i(x) = 0, \quad i \in E$$

és

$$c_i(x) \geq 0, \quad i \in I$$

- $f$ : célfüggvény
- $c_i$ : feltétel függvények
- $\{x \in \mathbb{R}^n : c_i(x) = 0 \text{ ha } i \in E, \quad c_i(x) \geq 0 \text{ ha } i \in I\}$ : megengedett tartomány

# Optimalizációs feladatok osztályozása


- diszkrét vs folytonos
- feltétel nélküli vs feltételes
- lokális vs globális
- determinisztikus vs sztochasztikus

# Feltétel nélküli optimalizálás

Adott  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  folyt. diff.ható fv, keresett

$$\min_x f(x)$$

- $x^*$  **globális minimumhely**, ha  $f(x^*) \leq f(x)$ , minden  $x \in \mathbb{R}^n$  esetén
- $x^*$  **lokális minimumhely**, ha  $x^*$ -nak van olyan  $\mathcal{N}$  környezete, hogy  $f(x^*) \leq f(x)$ , minden  $x \in \mathcal{N}$  esetén
- $x^*$  **szigorú lokális minimumhely**, ha  $x^*$ -nak van olyan  $\mathcal{N}$  környezete, hogy  $f(x^*) < f(x)$ , minden  $x \in \mathcal{N}$  esetén
- $x^*$  **izolált lokális minimumhely**, ha  $x^*$ -nak van olyan  $\mathcal{N}$  környezete, amiben nincs más lokális minimumhely



Az  $f(x) = x^2 \cos\left(\frac{12}{x}\right) + 2x^2$  függvény a  $[0.01, 1]$  intervallumon.

# Jelölések

## Gradiens

Ha  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  differenciálható, akkor az  $f$  függvény  $x$ -beli gradiense

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \vdots \\ \frac{\partial f}{\partial x_n}(x) \end{pmatrix}$$

## Hesse-mátrix

Ha  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  kétszer differenciálható, akkor az  $f$  függvény  $x$ -beli Hesse-mátrixa

$$\nabla^2 f(x) = \left( \frac{\partial^2 f}{\partial x_i \partial x_j}(x) \right)_{i,j} \in \mathbb{R}^{n \times n}$$

# Jelölések

## Jacobi-mátrix

Ha  $F : \mathbb{R}^n \rightarrow \mathbb{R}^m$  differenciálható, akkor az F Jacobi-mátrixa

$$F'(x) = \left( \frac{\partial F_i}{\partial x_j} \right)_{i,j} \in \mathbb{R}^{m \times n}$$

azaz

$$F'(x) = \begin{pmatrix} \frac{\partial F_1}{\partial x_1}(x) & \frac{\partial F_1}{\partial x_2}(x) & \cdots & \frac{\partial F_1}{\partial x_n}(x) \\ \frac{\partial F_2}{\partial x_1}(x) & \frac{\partial F_2}{\partial x_2}(x) & \cdots & \frac{\partial F_2}{\partial x_n}(x) \\ \vdots & & & \\ \frac{\partial F_m}{\partial x_1}(x) & \frac{\partial F_m}{\partial x_2}(x) & \cdots & \frac{\partial F_m}{\partial x_n}(x) \end{pmatrix}$$

**Megj.:** A Jacobi-mátrix  $i$ -edik sora  $\nabla F_i(x)^T$

## Feladatok

Számítsa ki az alábbi függvények gradiensét és Hesse-mátrixát!

(a)  $f(x_1, x_2) = x_1^2 x_2 - 3x_2^3 + \cos(x_1 x_2)$

(b)  $f(x_1, x_2, x_3) = x_1 x_2 x_3 - x_3 e^{x_1} + x_2^4 x_3^2$

## Feladatok

Határozza meg az alábbi függvények Jacobi-mátrixát!

(a)

$$f(x_1, x_2) = \begin{pmatrix} x_1^2 x_2 - 2x_2^3 \\ \sin(x_1 x_2) - 1 \\ 3 - x_1 - x_2 \end{pmatrix}$$

(b)

$$f(x_1, x_2, x_3) = \begin{pmatrix} e^{x_1 x_3} + x_2^3 \\ \cos(x_1 - 2x_2 + x_3) \end{pmatrix}$$

# Taylor-tétel

## Tétel

Ha  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  folytonosan differenciálható, és  $p \in \mathbb{R}^n$ , akkor

$$f(x + p) = f(x) + \nabla f(x + tp)^T p$$

valamely  $t \in (0, 1)$  esetén. Ha  $f$  kétszer folyt. differenciálható, akkor

$$f(x + p) = f(x) + \nabla f(x)^T p + \frac{1}{2} p^T \nabla^2 f(x + tp) p$$

valamely  $t \in (0, 1)$ -re.

# Kvadratikus függvény

## Definíció

Az  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  függvényt kvadratikus függvénynek nevezzük, ha

$$f(x) = \frac{1}{2}x^T Ax + b^T x + c$$

alakba írható, ahol  $A \in \mathbb{R}^{n \times n}$  szimmetrikus mátrix,  $b \in \mathbb{R}^n$ ,  $c \in \mathbb{R}$ .

## Példa.

$f : \mathbb{R}^2 \rightarrow \mathbb{R}$ , ahol

$$f(x) = \frac{1}{2}x^T \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} x + \begin{pmatrix} -1 \\ 4 \end{pmatrix}^T x + 5,$$

azaz

$$\begin{aligned} f(x) &= \frac{1}{2}(2x_1^2 + 3x_2^2 + 2x_1x_2) - x_1 + 4x_2 + 5 \\ &= x_1^2 + \frac{3}{2}x_2^2 + x_1x_2 - x_1 + 4x_2 + 5 \end{aligned}$$

# Kvadratikus függvény

## Példa

Írjuk fel mátrixos alakban az alábbi kvadratikus függvényt!

$$f(x_1, x_2) = 4x_1^2 + 6x_1x_2 + 6x_2^2 + 7x_1 - 3x_2 - 1$$

## Megoldás.

$$f(x) = \frac{1}{2} \underbrace{(2x_1^2 + 3x_1x_2 + 3x_2^2)}_{x^T A x} + \underbrace{(7x_1 - 3x_2)}_{b^T x} - 1$$

$$f(x) = \frac{1}{2} x^T \begin{pmatrix} 2 & \frac{3}{2} \\ \frac{3}{2} & 3 \end{pmatrix} x + \begin{pmatrix} 7 \\ -3 \end{pmatrix}^T x - 1$$

# Kvadratikus függvény gradiense, Hesse-mátrixa

Legyen  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  úgy definiálva, hogy

$$f(x) = \frac{1}{2}x^T Ax + b^T x + c,$$

ahol  $A \in \mathbb{R}^{n \times n}$  szimmetrikus,  $b \in \mathbb{R}^n$ ,  $c \in \mathbb{R}$ .

Ekkor

$$\nabla f(x) = Ax + b \quad \text{és} \quad \nabla^2 f(x) = A$$

# A lokális szélsőérték feltételei

## Tétel (A szélsőérték elsőrendű szükséges feltétele)

Ha  $x^*$  az  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  lokális minimumhelye, és  $f$  folytonosan differenciálható az  $x^*$  egy nyílt környezetében, akkor  $\nabla f(x^*) = 0$ .

## Definíció (Stacionárius pont)

Legyen  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ . Az  $x^*$  pontot stacionárius pontnak hívjuk, ha  $\nabla f(x^*) = 0$ .

## Megjegyzés


Ha  $x^*$  stacionárius pontja  $f$ -nek, akkor stacionárius pontja  $-f$ -nek is, azaz a stacionárius pont lokális maximum is lehet.

## Definíció (Nyeregpont)

Ha  $x^*$  olyan stacionárius pontja  $f$ -nek, amely se nem lokális minimum, se nem lokális maximum, akkor nyeregpontnak hívjuk.

## Példa

Legyen  $f(x) = x_1^2 - x_2^2$ . Ekkor  $\nabla f(x) = (2x_1, -2x_2)^T$ , így  $x = (0, 0)$  az egyetlen stacionárius pont, amely nyeregpont.




## Feladat (Rosenbrock-függvény)

Határozza meg az

$$f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$$

függvény stacionárius pontjait!



$$\nabla f(x) = \begin{pmatrix} -400(x_2 - x_1^2)x_1 + 2(x_1 - 1) \\ 200(x_2 - x_1^2) \end{pmatrix}$$

Az egyetlen stacionárius pont:


$$x = (1, 1)$$

## Feladat

Határozza meg az

$$f(x_1, x_2) = x_1^3 + x_2^3 - 3x_1 - 3x_2$$

függvény stacionárius pontjait!



$$\nabla f(x) = \begin{pmatrix} 3x_1^2 - 3 \\ 3x_2^2 - 3 \end{pmatrix}$$

Négy stacionárius pont:

- (1, 1), (1, -1),
- (-1, 1), (-1, -1)

# A lokális szélsőérték feltételei

## Tétel (A szélsőérték másodrendű szükséges feltételei)

Ha  $x^*$  az  $f$  egy lokális minimumhelye, továbbá  $\nabla^2 f$  létezik és folytonos az  $x^*$  egy nyílt környezetében, akkor

- $\nabla f(x^*) = 0$ ,
- $\nabla^2 f(x^*)$  pozitív szemidefinit.

## Tétel (A szélsőérték másodrendű elegendő feltételei)

Tegyük fel, hogy  $\nabla^2 f$  létezik és folytonos az  $x^*$  egy nyílt környezetében, továbbá

- $\nabla f(x^*) = 0$ ,
- $\nabla^2 f(x^*)$  pozitív definit.

Ekkor  $x^*$  szigorú lokális minimumhelye  $f$ -nek.

# A stacionárius pont típusai

## Tétel

Legyen  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  kétszer folytonosan differenciálható és  $\nabla f(x^*) = 0$ .

- Ha  $\nabla^2 f(x^*)$  pozitív definit, akkor  $f$ -nek  $x^*$ -ban szigorú lokális minimuma van.
- Ha  $\nabla^2 f(x^*)$  negatív definit, akkor  $f$ -nek  $x^*$ -ban szigorú lokális maximuma van.
- Ha  $\nabla^2 f(x^*)$  indefinit, akkor  $f$ -nek  $x^*$ -ban nyeregpontja van.

## Feladat (Rosenbrock-függvény)

Vizsgálja meg a Hesse-mátrix definitségét az

$$f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$$

függvény stacionárius pontjában.

A gradiens vektor:

$$\nabla f(x) = \begin{pmatrix} -400(x_2 - x_1^2)x_1 + 2(x_1 - 1) \\ 200(x_2 - x_1^2) \end{pmatrix}$$

Az egyetlen stacionárius pont: (1,1).

A Hesse-mátrix:

$$\nabla^2 f(x) = \begin{pmatrix} 1200x_1^2 - 400x_2 + 2 & -400x_1 \\ -400x_1 & 200 \end{pmatrix}$$

A Hesse-mátrix:

$$\nabla^2 f(x) = \begin{pmatrix} 1200x_1^2 - 400x_2 + 2 & -400x_1 \\ -400x_1 & 200 \end{pmatrix}$$

A Hesse-mátrix értéke az (1,1) pontban:

$$\nabla^2 f(1,1) = \begin{pmatrix} 802 & -400 \\ -400 & 200 \end{pmatrix}$$

Ez a mátrix pozitív definit, mert

$$\Delta_1 = 802 > 0$$

$$\Delta_2 = 802 \cdot 200 - 400^2 > 0,$$

így az (1,1) pontban a függvénynek minimuma van.

## Feladat

Vizsgálja meg a Hesse-mátrix definitségét az

$$f(x_1, x_2) = x_1^3 + x_2^3 - 3x_1 - 3x_2$$

függvény stacionárius pontjaiban!

A gradiens és a Hesse-mátrix:

$$\nabla f(x) = \begin{pmatrix} 3x_1^2 - 3 \\ 3x_2^2 - 3 \end{pmatrix}, \quad \nabla^2 f(x) = \begin{pmatrix} 6x_1 & 0 \\ 0 & 6x_2 \end{pmatrix}$$

A Hesse-mátrix a stacionárius pontokban:

$$\nabla^2 f(1, 1) = \begin{pmatrix} 6 & 0 \\ 0 & 6 \end{pmatrix},$$

ami pozitív definit ( $\Delta_1 > 0$ ,  $\Delta_2 > 0$ ), így az  $(1, 1)$  pont lokális minimumhely.

A Hesse-mátrix a stacionárius pontokban:

$$\nabla^2 f(-1, -1) = \begin{pmatrix} -6 & 0 \\ 0 & -6 \end{pmatrix},$$



ami negatív definit ( $\Delta_1 < 0$ ,  $\Delta_2 > 0$ ), így a  $(-1, -1)$  pont lokális maximumhely.

$$\nabla^2 f(-1, 1) = \begin{pmatrix} -6 & 0 \\ 0 & 6 \end{pmatrix},$$

ami indefinit ( $\Delta_1 < 0$ ,  $\Delta_2 < 0$ ), így a  $(-1, 1)$  pont nyeregpont.

$$\nabla^2 f(1, -1) = \begin{pmatrix} 6 & 0 \\ 0 & -6 \end{pmatrix},$$

ami indefinit ( $\Delta_1 > 0$ ,  $\Delta_2 < 0$ ), így az  $(1, -1)$  pont nyeregpont.





Az  $f(x_1, x_2) = x_1^3 + x_2^3 - 3x_1 - 3x_2$  függvény, a szintvonai és a stacionárius pontjai



## Feladat

Számítsa ki az alábbi függvény stacionárius pontjait, és vizsgálja meg melyik milyen típusú!



- (a)  $f(x_1, x_2) = x_1^4 + x_2^4 - 36x_1x_2$
- (b)  $f(x_1, x_2) = (x_1^2 + x_2^2)^2 - 2(x_1^2 - x_2^2) + 1$
- (c)  $f(x_1, x_2) = \frac{1}{6}x_1^3 - x_1 + \frac{1}{4}x_1x_2^2$
- (d)  $f(x_1, x_2) = \sin(x_1)\cos(x_2)$ , ha  $x \in [0, 2\pi) \times x \in [0, 2\pi)$
- (e)  $f(x_1, x_2) = x_1^2 + x_2^2 + \frac{1}{x_1^2x_2^2}$ , ha  $x_1, x_2 \neq 0$
- (f)  $f(x_1, x_2) = x_2(1 - x_1^2 - x_2^2)$





Az  $f(x_1, x_2) = x_1^4 + x_2^4 - 36x_1x_2$  függvény, a szintvonalai és a normált negatív gradiens mező.




Az  $f(x_1, x_2) = (x_1^2 + x_2^2)^2 - 2(x_1^2 - x_2^2) + 1$  függvény, a szintvonalai és a normált negatív gradiens mező.





Az  $f(x_1, x_2) = \frac{1}{6}x_1^3 - x_1 + \frac{1}{4}x_1x_2^2$  függvény, a szintvonalai és a normált negatív gradiens mező.



Az  $f(x_1, x_2) = \sin(x_1)\cos(x_2)$  függvény, a szintvonali és a normált negatív gradiens mező.



A  $f(x_1, x_2) = x_1^2 + x_2^2 + \frac{1}{x_1^2 x_2^2}$  függvény, a szintvonalai és a normált negatív gradiens mező.



A  $f(x_1, x_2) = x_2(1 - x_1^2 - x_2^2)$  függvény, a szintvonali és a normált negatív gradiens mező.

# Konvexitás

## Definíció (Konvex halmaz)

Az  $S \subset \mathbb{R}^n$  halmaz konvex, ha bármely  $x \in S$ ,  $y \in S$  és  $t \in [0, 1]$  esetén  $tx + (1 - t)y \in S$ .

## Definíció (Konvex, konkáv függvény)

Az  $f : S \rightarrow \mathbb{R}$  függvény konvex, ha  $S$  konvex és

$$f(tx + (1 - t)y) \leq tf(x) + (1 - t)f(y), \quad \forall x, y \in S, \quad \forall t \in [0, 1]$$

Az  $f$  konkáv, ha  $-f$  konvex.

Az  $f$  szigorúan konvex, ha

$$f(tx + (1 - t)y) < tf(x) + (1 - t)f(y), \quad \forall x, y \in S, x \neq y \quad \forall t \in (0, 1)$$

# Konvex függvények

## Példák konvex függvényre

- Az  $f(x) = c^T x + b$  függvény, ahol  $x \in \mathbb{R}^n$ , és  $c \in \mathbb{R}^n$  és  $b \in \mathbb{R}$  tetszőleges konstansok.
- Az  $f(x) = x^T Ax$  függvény, ahol  $x \in \mathbb{R}^n$ , és  $A \in \mathbb{R}^{n \times n}$  pozitív szemidefinit mátrix

### Tétel

Ha  $f$  konvex, akkor minden lokális minimumhely globális minimumhely. Ha  $f$  még differenciálható is, akkor minden stacionárius pont globális minimumhely.

### Tétel


Ha  $f$  egy konvex, nyílt halmazon értelmezett függvény, mely kétszer folytonosan differenciálható, akkor  $f$  pontosan akkor konvex, ha  $\nabla^2 f(x)$  pozitív szemidefinit minden  $x$  esetén.

# Konvex kvadratikus függvények, példák


$$f(x) = x^T A x, \text{ ahol}$$

$$A = \begin{pmatrix} a & 0 \\ 0 & a \end{pmatrix}, \quad a > 0.$$

Ekkor a függvénynek globális minimuma van  $(0, 0)$ -ban, a szintvonai origó középpontú körök.



$$f(x) = 3x_1^2 + 3x_2^2 \quad (a = 3)$$





# Konvex kvadratikus függvények, példák

$$f(x) = x^T A x, \text{ ahol}$$

$$A = \begin{pmatrix} a & 0 \\ 0 & b \end{pmatrix}, \quad a, b > 0, \quad a \neq b.$$

Globális minimum  $(0, 0)$ -ban, a szintvonalak origó középpontú ellipszisek, tengelyeik párhuzamosak a koordinátatengelyekkel. Ha  $a > b$ , akkor az  $x_2$ -tengely, ha  $a < b$ , akkor az  $x_1$ -tengely irányában nyújtottak a szintvonalak.





$$f(x) = 3x_1^2 + x_2^2 \quad (a = 3, b = 1)$$

# Konvex kvadratikus függvények, példák

$f(x) = x^T Ax$ , ahol

$$A = \begin{pmatrix} a & c \\ c & b \end{pmatrix}, \quad a > 0, \quad b, c \neq 0, \quad ab - c^2 > 0.$$

Globális minimum  $(0, 0)$ -ban, a szintvonalak origó középpontú ellipszisek, tengelyeiik **nem** párhuzamosak a koordinátatengelyekkel.





$$f(x) = 3x_1^2 + 3x_2^2 + 2x_1x_2 \quad (a = 3, b = 3, c = 1)$$

# Konvex kvadratikus függvények, példák

$$f(x) = x^T A x + d^T x, \text{ ahol}$$

$$A = \begin{pmatrix} a & c \\ c & b \end{pmatrix}, \quad d = \begin{pmatrix} d_1 \\ d_2 \end{pmatrix}, \quad a > 0, \quad b, c, d_1, d_2 \neq 0, \quad ab - c^2 > 0.$$

A szintvonalak **nem** origó középpontú ellipszisek, tengelyeik **nem** párhuzamosak a koordinátatengelyekkel.



$$f(x) = 3x_1^2 + 3x_2^2 + 2x_1x_2 + 3x_1 - x_2 \quad (a = 3, b = 3, c = 1, d_1 = 3, d_2 = -1)$$

# Optimalizáló eljárások

- (1) Egy  $x_0$  kezdeti közelítés megadása
- (2) Az  $x_k \rightarrow x_{k+1}$  stratégia meghatározása
- (3) Leállási feltétel

Két alapvető stratégia:

- Vonalmenti keresés

Meghatározunk egy  $p_k$  irányt, amerre csökken a függvény, és ebben az irányban egy egyváltozós minimalizálást hajtunk végre.

$$\min_{\alpha} f(x_k + \alpha p_k)$$

- Megbízhatósági tartomány alapú  
 $f$ -et az  $x_k$  környezetében lokálisan egy  $m_k$  modellfüggvénnnyel közelítjük, és  $f$  helyett  $m_k$ -t minimalizáljuk, a megbízhatósági tartományon belül.

$$\min_p m_k(x_k + p), \quad \text{ahol } x_k + p \text{ a tartományban van}$$

## Vonalmenti keresések, a keresési irány

A  $p$  keresési irány megválasztása: csökkenjen a függvény.

A Taylor-tételből: kicsi  $\alpha$  esetén

$$f(x_k + \alpha p) \approx f(x_k) + \alpha p^T \nabla f_k.$$

### Csökkenési irány

A  $p \in \mathbb{R}^n$  irány  $x$ -beli csökkenési irány (leereszkedési irány), ha  $p^T \nabla f(x) < 0$ .

Mivel

$$p^T \nabla f_k = \|p\| \cdot \|\nabla f_k\| \cos \Theta,$$

ha  $\cos \Theta < 0$ , akkor  $p^T \nabla f_k < 0$

### Legmeredekebb leereszkedés (Gradiens módszer)

Ha  $p = -\nabla f_k$  (azaz  $\cos \Theta = -1$ ).

# Vonalmenti keresések - lépéshossz választás

Ha adott a  $p_k$  keresési irány, akkor az

$$\alpha \mapsto f(x_k + \alpha p_k), \quad (\alpha > 0)$$

egyváltozós függvényt kellene minimalizálni.

A minimumhely meghatározása túl költséges lehet, ezért sokszor beérjük egy „elég jó”  $\alpha$  értékkel.

## Két lépés:

- Meghatározunk egy intervallumot, ahol  $\alpha$ -t keressük (max. lépéshossz)
- Az adott intervallumon keresünk egy elegendően jó  $\alpha$ -t (amire  $f(x_k + \alpha p_k)$  elegendő mértékben kisebb  $f(x_k)$ -nál)

## Vonalmenti keresések - lépéshossz választás

Úgy választjuk a lépéshosszt, hogy a függvény „elegendő mértékben” csökkenjen.

### Armijo-feltétel

Legyen  $c_1 \in (0, 1)$  adott. Azt mondjuk, hogy az  $\alpha_k$  lépéshossz teljesíti az Armijo-feltételt, ha

$$f(x_k + \alpha_k p_k) \leq f(x_k) + \alpha_k c_1 \nabla f_k^T p_k$$

Egy lehetséges algoritmus  $\alpha_k$  megválasztására (**visszaléptetéses módszer**):

Legyen  $c_1 \in (0, 1)$ ,  $\varrho \in (0, 1)$  rögzített,  $\alpha := \alpha_0$ .

while  $f(x_k + \alpha p_k) > f(x_k) + \alpha c_1 \nabla f_k^T p_k$

$\alpha := \varrho \alpha$

end

$\alpha_k = \alpha$ , stop.

# Vonalmenti keresések - lépéshossz választás

**A lépéshossz ne legyen túl rövid:**

Valamely  $c_2 \in (c_1, 1)$  esetén

$$\nabla f(x_k + \alpha_k p_k)^T p_k \geq c_2 \nabla f_k^T p_k$$

teljesüljön.

## Wolfe-feltételek

Valamely  $0 < c_1 < c_2 < 1$  esetén teljesüljön, hogy

$$f(x_k + \alpha_k p_k) \leq f(x_k) + \alpha_k c_1 \nabla f_k^T p_k,$$

$$\nabla f(x_k + \alpha_k p_k)^T p_k \geq c_2 \nabla f_k^T p_k$$

A visszaléptetéses módszer általában biztosítja a Wolfe-feltételek teljesülését.

## Gradiens módszer visszaléptetéssel

- (1) Legyen adott  $x_0$
- (2) Ha ismert  $x_k$ , akkor legyen  $p_k = -\nabla f_k$
- (3) Válasszuk  $\alpha_k$ -t a visszaléptetéses módszerrel
- (4) Legyen  $x_{k+1} = x_k + \alpha_k p_k$ .
- (5) Leállás: ha  $\nabla f_k = 0$  (ha  $\|\nabla f_k\| < \varepsilon$ )


### Tétel.

Legyen  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  folytonosan differenciálható. Ekkor az előző algoritmus vagy véges sok lépésben megáll egy  $x_k$  stacionárius pontnál, vagy egy szigorúan monoton csökkenő sorozatot állít elő, melynek minden torlódási pontja stacionárius pont.

### Megjegyzés


A gradiens módszer nagyon lassú lehet hosszú, elnyújtott völgyek esetén ( $\rightarrow$  skálázás).

# Gradiens módszer




Az  $f(x_1, x_2) = x_1^3 + x_2^3 - 3x_1 - 3x_2$  függvény.

# Gradiens módszer




Az  $f(x_1, x_2) = x_1^3 + x_2^3 - 3x_1 - 3x_2$  függvény szintvonalai és stacionárius pontjai.

# Gradiens módszer



Az  $f(x_1, x_2) = x_1^3 + x_2^3 - 3x_1 - 3x_2$  függvény szintvonalai és a negatív gradiens mező.

# Gradiens módszer



Az


$$f(x_1, x_2) = x_1^3 + x_2^3 - 3x_1 - 3x_2$$

és a

$$f(x_1, x_2) = 10x_1^3 + x_2^3 - 30x_1 - 3x_2$$

függvény szintvonalaiból.

# Gradiens módszer



Az


$$f(x_1, x_2) = x_1^3 + x_2^3 - 3x_1 - 3x_2$$

és a

$$f(x_1, x_2) = 10x_1^3 + x_2^3 - 30x_1 - 3x_2$$

függvény szintvonalaiból és a negatív gradiensmezők.


# Gradiens módszer



A gradiens módszer az  $f(x_1, x_2) = x_1^3 + x_2^3 - 3x_1 - 3x_2$  függvény esetén.

$x_0$	(-0.5, -0.5)	(0, -0.9)	(-1, 0)
lépés	6	11	2
$x^*$	(1.0000, 1.0000)	(1.0000, 0.9999)	(-1, 1)

# Gradiens módszer



A gradiens módszer az  $f(x_1, x_2) = 10x_1^3 + x_2^3 - 30x_1 - 3x_2$  függvény esetén.

$x_0$	(-0.5, -0.5)	(0, -0.9)	(-1, 0)
lépésszám	36	33	2
$x^*$	(1.0000, 0.9999)	(1.0000, 1.0001)	(-1, 1)

# A gradiens-módszer konvergenciarendje

Az „ideális” esetben, amikor a célfüggvény kvadratikus és egzakt vonalmenti keresést használunk (azaz az adott irány mentén a tényleges minimumot biztosító lépéshosszt választjuk).

Legyen

$$f(x) = \frac{1}{2}x^T Qx - b^T x,$$

ahol  $Q$  szimmetrikus és pozitív definit. Ekkor  $\nabla f(x) = Qx - b$ , azaz  $Qx^* = b$ . Az optimális lépéshossz:

$$\alpha_k = \frac{\nabla f_k^T \nabla f_k}{\nabla f_k^T Q \nabla f_k},$$

azaz

$$x_{k+1} = x_k - \left( \frac{\nabla f_k^T \nabla f_k}{\nabla f_k^T Q \nabla f_k} \right) \nabla f_k$$

# A gradiens-módszer konvergenciarendje

## Tétel.

Ha az előző kvadratikus függvényre alkalmazzuk a gradiens módszert egzakt vonalmenti kereséssel, és  $\|x\|_Q = x^T Q x$  (ez norma lesz), akkor

$$\|x_{k+1} - x^*\|_Q^2 \leq \left( \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^2 \|x_k - x^*\|_Q^2,$$

ahol  $0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$  a  $Q$  sajátértékei.

- Megj.:**  $Qx^* = b$ -ből következik, hogy  $\frac{1}{2}\|x_k - x^*\|_Q^2 = f_k - f_*$ .
- Megj.:** Ha  $\lambda_1 = \lambda_n$ , akkor 1 lépésben elérjük az optimumot.  
Ahogy nő  $\frac{\lambda_n}{\lambda_1}$  úgy válnak egyre elnyújtottabbá az  $f$  kontúrvonalai, és egyre „cikk-cakk”-osabbá a sorozat.

# A gradiens-módszer konvergenciarendje

**Példa.** Legyen  $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ ,  $f(x) = x_1^2 + ax_2^2$ , ahol  $a > 1$ . Ekkor  $f(x) = x^T Qx$ , ahol


$$Q = \begin{pmatrix} 2 & 0 \\ 0 & 2a \end{pmatrix}$$

Ha  $x_0 = (a, 1)^T$ , akkor

$$x_k = \begin{cases} \left(\frac{a-1}{a+1}\right)^k \begin{pmatrix} a \\ 1 \end{pmatrix} & k \text{ páros} \\ \left(\frac{a-1}{a+1}\right)^k \begin{pmatrix} a \\ -1 \end{pmatrix} & k \text{ páratlan} \end{cases}$$


A  $Q$  mátrix sajátértékei  $2$  és  $2a$ .

# Gradiens módszer



A gradiens módszer az  $f(x_1, x_2) = x_1^2 + 10x_2^2$  függvényre.

# Gradiens módszer



A visszaléptetéses gradiens módszer a Rosenbrock-függvényre, az utolsó 130 iterált.  $x_0 = (-1.2, 1)$ ,  $\varepsilon = 10^{-3}$ ,  $\varrho = 0.5$ . Az elvégzett lépések száma 5231.

# Newton-módszer nemlineáris egyenletek gyökeinek közelítésére

## Emlékeztető:

Az  $f(x) = 0$  (ahol  $f : \mathbb{R} \rightarrow \mathbb{R}$ ) **nemlineáris egyenlet** gyökének közelítésére szolgáló Newton-iteráció:

$$x_0 \text{ adott}, \quad x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}, \quad k = 0, 1, 2, \dots$$

Az  $F(x) = 0$  (ahol  $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ ) **nemlineáris egyenletrendszer** gyökének közelítésére szolgáló Newton-iteráció:

$$x_0 \text{ adott}, \quad F'(x_k)(x_{k+1} - x_k) = -F(x_k), \quad k = 0, 1, 2, \dots$$

# Newton-módszer optimalizálásra

Az  $f$  függvény minimumhelye megoldása a  $\nabla f(x) = 0$  egyenletnek.  
Mivel  $\nabla f : \mathbb{R}^n \rightarrow \mathbb{R}^n$ , ezért ez egy nemlineáris egyenletrendszer.

Ha  $f$  kétszer folytonosan differenciálható, akkor a Newton-módszer a  $\nabla f(x) = 0$  egyenletre:

$$x_0 \text{ adott}, \quad \nabla^2 f(x_k)(x_{k+1} - x_k) = -\nabla f(x_k), \quad k = 0, 1, 2, \dots$$

azaz

- $x_0$  adott,
- $\nabla^2 f(x_k)p_k = -\nabla f(x_k)$ , (azaz  $p_k = -(\nabla^2 f_k)^{-1}\nabla f_k$ )
- $x_{k+1} = x_k + p_k$
- ha  $\|\nabla f_k\| < \varepsilon$ , akkor leállás

# Newton-módszer optimalizálásra

## Tétel.

Tehát  $f$  kétszer folytonosan differenciálható,  $\nabla f(x^*) = 0$ ,  $\nabla^2 f(x^*)$  poz. definit és létezik olyan  $L > 0$  konstans, hogy


$$\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq L\|x - y\|,$$

$\forall x, y$ -ra az  $x^*$  egy környezetéből. Ekkor a Newton-iterációt az  $x^*$  egy elegendően jó környezetéből indítva az iteráció konvergál  $x^*$ -hoz, a konvergencia négyzetes, és az  $\{\|\nabla f_k\|\}$  sorozat négyzetesen tart 0-hoz.

## Problémák.

- A Hesse-mátrix számítása költséges
- A Hesse mátrix (ha nem a minimumhely egy jó környezetében vagyunk) nem feltétlenül pozitív definit.

# Newton-módszer, példa



A Newton-módszer a Rosenbrock-függvényre.  $x_0 = (-1.2, 1)$ ,  
 $x_{opt} = (0.999996, 0.999991)$ ,  $f(x_{opt}) = 1.8 \cdot 10^{-11}$ ,  $k = 5$ .

# Newton-módszer, másik megközelítésből

A Taylor-sorból:

$$f(x_k + p) \approx f_k + p^T \nabla f_k + \frac{1}{2} p^T \nabla^2 f_k p =: m_k(p)$$

Ha  $\nabla^2 f_k$  pozitív definit, akkor  $m_k(p)$  minimumhelye

$$p_k^N = -(\nabla^2 f_k)^{-1} \nabla f_k$$

## Newton-irány

Reguláris  $\nabla^2 f_k$  esetén a  $p_k^N = -(\nabla^2 f_k)^{-1} \nabla f_k$  irányt Newton-iránynak nevezzük.

Ha  $\nabla^2 f_k$  pozitív definit, akkor a Newton-irány csökkenési irány:

$$\nabla f_k^T p_k^N = -p_k^{NT} \nabla^2 f_k p_k^N < 0.$$

Ha  $\nabla^2 f_k$  nem pozitív definit, akkor előfordulhat, hogy a Newton-irány nem definiált, vagy nem csökkenési irány.

A Newton-irány előnye: a minimumhely elég jó közelítése esetén négyzetes konvergencia, hátránya: szükség van a Hesse-mátrixra.

### Kvázi-Newton irány

$$p_k = -B_k^{-1} \nabla f_k, \text{ ahol } B_k \approx \nabla^2 f_k$$

$B_k$  alkalmas megválasztása esetén nincs szükség a Hesse-mátrixra, de a konvergencia szuperlineáris marad.

# Módosított Newton-módszer

Ha  $\nabla^2 f_k$  nem pozitív definit, akkor helyettesítsük egy pozitív definit  $B_k = \nabla^2 f_k + E_k$  mátrixszal.

- $x_0$  adott
- $x_k \mapsto x_{k+1}$ :
  - ▶  $B_k = \nabla^2 f_k + E_k$ , ahol  $E_k = 0$ , ha  $\nabla^2 f_k$  „elegendően” pozitív definit, egyébként egy olyan mátrix, hogy  $B_k$  „elegendően” poz.def. legyen
  - ▶ megoldjuk a  $B_k p_k = -\nabla f_k$  egyenletrendszer,
  - ▶  $x_{k+1} = x_k + \alpha_k x_k$ , ahol  $\alpha_k$ -t úgy választjuk, hogy teljesítse a Wolfe feltételeket.
- leállás: ha  $\|\nabla f_k\| < \varepsilon$

# Módosított Newton-módszer

## Tétel

Ha  $f$  kétszer folytonosan differenciálható és  $x_0$  olyan, hogy a  $\{x : f(x) \leq f(x_0)\}$  nívóhalmaz kompakt. Ha létezik olyan  $C$ , hogy  $\text{cond}(B_k) \leq C$  minden  $k = 1, 2, \dots$  esetén, akkor

$$\lim \nabla f_k = 0$$

## Megjegyzés.

Ha  $x^*$  olyan, hogy  $\nabla^2 f(x^*)$  elegendően pozitív definit, akkor elég nagy  $k$  esetén  $E_k = 0$  lesz és  $\alpha_k = 1$ , a konvergencia pedig négyzetessé válik.

## Probléma:

Hogyan találjuk meg a megfelelő  $B_k$  mátrixot?

# Mátrixok szinguláris felbontása

## Tétel.

Tetszőleges  $A \in \mathbb{R}^{m \times n}$  mátrixnak létezik

$$A = USV^\top$$

alakú felbontása, ahol  $U \in \mathbb{R}^{m \times m}$  és  $V \in \mathbb{R}^{n \times n}$  ortogonális mátrixok,  $S \in \mathbb{R}^{m \times n}$  pedig egy diagonális mátrix, melynek főátlójában a  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min\{m,n\}} \geq 0$  valós értékek állnak, amiket az  $A$  szinguláris értékeinek nevezünk.

## Megjegyzés.

- $\sigma_i^2 = \lambda_i(A^T A)$ .
- A pozitív sziguláris értékek száma megegyezik az  $A$  mátrix  $r$  rangjával.

# Mátrixok szinguláris felbontása

Legyen  $A$  rangja  $r$ , ekkor a szinguláris felbontás:

$$A = \sum_{i=1}^r \sigma_i u_i v_i^\top,$$

ahol  $u_i$ , illetve  $v_i$  rendre az  $U$ , illetve  $V$  mátrix  $i$ -edik oszlopa.

Az  $A$  mátrixot 1-rangú mátrixok összegére bontottuk.



A szinguláris értékek monoton csökkenő módon követik egymást  $\rightarrow$  az összegben szereplő mátrixok súlya ugyanígy monoton csökken.

## Szinguláris felbontás, példa.



$512 \times 512$  pixeles kép  $\rightarrow A \in \mathbb{R}^{512 \times 512}$ .

## Szinguláris felbontás, példa.



Az  $A$  mátrix szinguláris értékei normál, és logaritmikus skálán.

$$\sigma_1 = 253.87.$$

## Szinguláris felbontás, példa.



A B mátrix

Hagyjuk el az utolsó 112 szinguláris értékhez tartozó 1-rangú mátrixot.

$A B = \sum_{i=1}^{400} \sigma_i u_i v_i^T$  mátrix ( $\sigma_{400} = 0.1021$ ).

## Szinguláris felbontás, példa.



A B mátrix

Hagyjuk el az utolsó 312 szinguláris értékhez tartozó 1-rangú mátrixot.

$$A B = \sum_{i=1}^{200} \sigma_i u_i v_i^T \text{ mátrix } (\sigma_{200} = 0.4265).$$

## Szinguláris felbontás, példa.



A B mátrix

Hagyjuk el az utolsó 412 szinguláris értékhez tartozó 1-rangú mátrixot.

$A B = \sum_{i=1}^{100} \sigma_i u_i v_i^T$  mátrix ( $\sigma_{100} = 1.2676$ ).

## Szinguláris felbontás, példa.



A B mátrix

Hagyjuk el az utolsó 462 szinguláris értékhez tartozó 1-rangú mátrixot.

$$A B = \sum_{i=1}^{50} \sigma_i u_i v_i^T \text{ mátrix } (\sigma_{50} = 2.7572).$$

# Szimmetrikus mátrixok spektrál felbontása

## Tétel.

Legyen  $A \in \mathbb{R}^{n \times n}$  egy szimmetrikus mátrix,  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$  az  $A$  (valós) sajátértékei,  $q_1, q_2, \dots, q_n$  pedig a megfelelő ortonormált sajátvektorok. Az  $A$  mátrix spektrál felbontása

$$A = \sum_{i=1}^n \lambda_i q_i q_i^\top.$$

Mátrixos alakban

$$A = Q \Lambda Q^\top,$$

ahol  $Q$  az az ortogonális mátrix melynek oszlopai a  $q_1, q_2, \dots, q_n$  sajátvektorok és  $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ .

**Megjegyzés.** Szimmetrikus, pozitív definit mátrix esetén a spektrál felbontás éppen a szinguláris felbontással egyenlő.

# Módosított Newton-módszer

Hogyan válasszuk meg a  $B_k$  mátrixot?

Legyen  $\nabla^2 f_k = \sum_{i=1}^n \lambda_i q_i q_i^T$  a Hesse-mátrix spektrál felbontása.

Lehetőségek:

- a negatív sajátértékeket kicsi pozitív értékekre cseréljük,
- elhagyjuk a negatív sajátértékekhez tartozó tagjait a keresési iránynak
- minden sajátértéket eltolunk:  $Q(\Lambda + diag(\tau_i))Q^T$

**Megj.:**

A spektrál felbontás költséges. Egy egyszerűbb megoldás:  $B_k = \nabla^2 f_k + \tau E$

# Kvázi-Newton módszerek

Emlékeztető:

$$f(x_k + p) \approx f_k + p^T \nabla f_k + \frac{1}{2} p^T \nabla^2 f_k p.$$

Az  $f$  közelítésére az

$$m_k(p) = f_k + p^T \nabla f_k + \frac{1}{2} p^T B_k p$$

kvadratikus modellfüggvényt használjuk, ahol a  $B_k$  mátrix szimmetrikus és pozitív definit.

Ekkor az  $x_k \mapsto x_{k+1}$  stratégia:

$$p_k = -B_k^{-1} \nabla f_k \quad (\text{az egzakt minimumhely}),$$

$$x_{k+1} = x_k + \alpha_k p_k \quad (\text{Wolfe-feltételek!}).$$

# Kvázi-Newton módszerek

## $B_k$ módosítása

A szelő egyenlet:

$$B_{k+1}s_k = y_k,$$

ahol  $s_k = x_{k+1} - x_k$  és  $y_k = \nabla f_{k+1} - \nabla f_k$ .

Ez csak akkor megoldható, ha

$$s_k^T y_k > 0$$

(görbületi feltétel).

A  $B_{k+1}$  meghatározásához tekintsük a

$$\min_B \|B - B_k\|,$$

feladatot a  $B^T = B$  és  $Bs_k = y_k$  feltételek mellett.

# Kvázi-Newton módszerek

Különböző normák  $\min_B \|B - B_k\| \implies$  különböző módszerek.

Súlyozott Frobenius-norma  $\implies$  **Davidon-Fletcher-Powell** (DFP) formula:

$$B_{k+1} = \left( I - \frac{y_k s_k^T}{y_k^T s_k} \right) B_k \left( I - \frac{s_k y_k^T}{y_k^T s_k} \right) + \frac{y_k y_k^T}{y_k^T s_k}.$$

Ekkor a  $H_k = B_k^{-1}$  jelölést használva:

$$H_{k+1} = H_k - \frac{H_k y_k y_k^T H_k}{y_k H_k y_k} + \frac{s_k s_k^T}{y_k^T s_k}$$

# Kvázi-Newton módszerek

$B_k$  helyett  $H_k$ -ra alkalmazva a feltételeket:

**Broyden-Fletcher-Goldfarb-Shanno (BFGS) módszer**

$$H_{k+1} = \left( I - \frac{s_k y_k^T}{y_k^T s_k} \right) H_k \left( I - \frac{y_k s_k^T}{y_k^T s_k} \right) + \frac{s_k s_k^T}{y_k^T s_k}.$$

vagy


$$B_{k+1} = B_k - \frac{B_k s_k s_k^T B_k}{s_k H_k s_k} + \frac{y_k y_k^T}{y_k^T s_k}$$

Megfelelő feltételek teljesülése esetén a BFGS algoritmus szuperlineáris rendben konvergál  $x^*$ -hoz.

## A BFGS algoritmus előnyei:

- szuperlineáris konvergencia
- skálázás-invariáns
- „önjavító”: ha  $H_k$  nem túl jól approximálja a Hesse-mátrix inverzét, pl.  $y_k^T s_k$  pozitív, de 0-hoz közelí, az iteráció általában néhány lépés után korrigálja a hibát (megfelelő vonalmenti keresés esetén).

## BFGS módszer, példa.



BFGS módszer a Rosenbrock függvényre.  $x_0 = (-1.2, 1)$ ,  $k = 32$ ,  
 $x_{opt} = (0.9999997, 0.9999993)$ ,  $f(x_{opt}) = 1.87 \cdot 10^{-13}$ .

# Kvázi-Newton módszerek

## A szimmetrikus 1-rangú formula (SR1)

$$B_{k+1} = B_k + \frac{(y_k - B_k s_k)(y_k - B_k s_k)^T}{(y_k - B_k s_k)^T s_k}$$

és

$$H_{k+1} = H_k + \frac{(s_k - H_k y_k)(s_k - H_k y_k)^T}{(s_k - H_k y_k)^T y_k}$$

Az algoritmus a Hesse-mátrix jó approximációját adja.

Hátrányai:

- nem biztos, hogy  $B_{k+1}$  pozitív definit
- a nevező 0 is lehet

## Kiegészítő anyag: arcfelismerés, SVD

Olivetti adatbázis:  $40 \times 10$  pgm kép.

A: az i-edik oszlopában az i-edik kép vektorralakban.

Készítsük el az A szinguláris felbontását:  $A = USV^T$ .

Az U oszlopai: „eigenfaces”. Az első 15:



Képek rekonstrukciója az  $U$  első 1, 3, 5, 8, 10, 15, 20, 30, 40 oszlopából:



Eredeti kép:



Képek rekonstrukciója az  $U$  első 1, 3, 5, 8, 10, 15, 20, 30, 40 oszlopából:



Eredeti kép:



Képek rekonstrukciója az  $U$  első 1, 3, 5, 8, 10, 15, 20, 30, 40 oszlopából:



Eredeti kép:



# Feltételes optimalizálás

## A feladat:

Keresett

$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{amikor} \quad \begin{cases} c_i(x) = 0, & i \in \mathcal{E} \\ c_i(x) \geq 0, & i \in \mathcal{I} \end{cases}$$

ahol  $f$  és  $c_i$  sima, valós értékű függvények.

- $f$ : célfüggvény
- $c_i$ : feltétel függvények
- $\Omega = \{x \in \mathbb{R}^n : c_i(x) = 0 \text{ ha } i \in \mathcal{E}, \quad c_i(x) \geq 0 \text{ ha } i \in \mathcal{I}\}$ : megengedett pontok halmaza
- $x$  megengedett, ha  $x \in \Omega$

## Aktív halmaz

Adott  $x$  megengedett pont esetén

$$\mathcal{A}(x) = \mathcal{E} \cup \{i \in \mathcal{I} : c_i(x) = 0\}$$

Egy  $x$  megengedett pont esetén az  $i \in \mathcal{I}$  egyenlőtlenség aktív, ha  $c_i(x) = 0$ , és inaktív ha  $c_i(x) > 0$ .

## Lokális megoldás

$x^* \in \mathbb{R}$  lokális megoldás, ha  $x^* \in \Omega$  és létezik  $x^*$ -nak olyan  $N$  környezete, hogy  $f(x) \geq f(x^*)$  for  $x \in \Omega \cap N$ .

## Szigorú lokális megoldás

$x^* \in \mathbb{R}$  szigorú lokális megoldás, ha  $x^* \in \Omega$  és létezik  $x^*$ -nak olyan  $N$  környezete, hogy  $f(x) > f(x^*)$  ha  $x \in \Omega \cap N$ ,  $x \neq x^*$ .

## LICQ (linear independence constraint qualification)

Adott  $x \in \Omega$  és  $\mathcal{A}(x)$  esetén azt mondjuk, hogy a LICQ feltételek teljesülnek, ha az aktív feltételek gradiensei lineárisan függetlenek, azaz a

$$\{\nabla c_i(x) : i \in \mathcal{A}(x)\}$$

halmaz elemei lineárisan függetlenek.

## Lagrange-függvény

A feltételes minimalizálási feladat Lagrange-függvénye

$$\mathcal{L}(x, \lambda) = f(x) - \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i c_i(x)$$

## Elsőrendű szükséges feltételek (Karush-Kuhn-Tucker feltételek)

Tehát  $x^*$  lokális megoldás,  $f$  és  $c_i$  folytonosan differenciálható, továbbá a LICQ feltételek teljesülnek  $x^*$ -ban. Ekkor létezik olyan  $\lambda^*$ , hogy az alábbi feltételek teljesülnek:

- $\nabla_x \mathcal{L}(x^*, \lambda^*) = 0$ ,
- $c_i(x^*) = 0$  minden  $i \in \mathcal{E}$  esetén,
- $c_i(x^*) \geq 0$  minden  $i \in \mathcal{I}$  esetén,
- $\lambda_i^* \geq 0$  minden  $i \in \mathcal{I}$  esetén,
- $\lambda_i^* c_i(x^*) = 0$  minden  $i \in \mathcal{E} \cup \mathcal{I}$  esetén.

## Egyenlőségekkel adott feltételek

Tegyük fel, hogy egyetlen feltétel van és az egyenlőséggel adott:

$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{amikor } c(x) = 0.$$

Ekkor a Lagrange-függvény:

$$\mathcal{L}(x, \lambda) = f(x) - \lambda c(x).$$

Legyen  $x$  egy megengedett pont, vizsgáljuk meg, hogy innen  $\delta x$ -et elmozdulva a megengedett pontok halmazában hogy változik az  $f$  értéke.

$$f(x + \delta x) \approx f(x) + \nabla^T f(x) \cdot \delta x$$

Ha csökkenési irányban szeretnénk elmozdulni, akkor kicsi  $\delta x$  esetén teljesülni kell, hogy

$$\nabla^T f(x) \cdot \delta x < 0$$

Mivel

$$c(x + \delta x) \approx c(x) + \nabla^T c(x) \cdot \delta x,$$

így ha azt szeretnénk, hogy  $x$  mellett  $x + \delta x$  is megengedett legyen (azaz  $c(x) = 0$  mellett  $c(x + \delta x) = 0$  is teljesüljön), akkor a

$$\nabla^T c(x) \cdot \delta x = 0$$

feltételnek is teljesülni kell. Azaz amíg egy adott  $x$  pont esetén tudunk olyan  $\delta x$  irányt választani, hogy

$$\nabla^T f(x) \cdot \delta x < 0 \quad \text{és} \quad \nabla^T c(x) \cdot \delta x = 0,$$

addig tudjuk csökkenteni az  $f$  értékét a megengedett tartományon belül.

Ilyen  $\delta x$  irány csak akkor nem létezik, ha valamely  $\lambda$  esetén  $\nabla f(x) = \lambda \nabla c(x)$ , azaz

$$\nabla_x \mathcal{L}(x, \lambda) = 0.$$

Tehát egy  $x^*$  pont akkor lehet lokális minimumhely, ha valamely  $\lambda^*$  esetén

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = 0.$$

(KKT 1. feltétel.)

A KKT 2. feltétel ( $c(x^*) = 0$ ) ekvivalens azzal, hogy

$$\nabla_\lambda \mathcal{L}(x^*, \lambda^*) = 0,$$

és a KKT 5. feltétel is automatikusan teljesül.

A több egyenlőséggel adott feltételrendszer esete ugyanígy vizsgálható.

**Megjegyzés:** Az, hogy KKT feltételekkel megtalált pont valóban lokális minimumhely, további vizsgálatokat igényel.

# Egyenlőtlenségekkel adott feltételek

Tegyük fel, hogy egyetlen feltétel van és az egyenlőtlenséggel adott:

$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{amikor } c(x) \geq 0.$$

Ekkor a Lagrange-függvény:

$$\mathcal{L}(x, \lambda) = f(x) - \lambda c(x).$$

Legyen  $x$  egy megengedett pont, vizsgáljuk meg, hogy innen  $\delta x$ -et elmozdulva a megengedett pontok halmazában hogy változik az  $f$  értéke.

Ha csökkenési irányban szeretnénk elmozdulni, akkor kicsi  $\delta x$  esetén teljesülni kell, hogy

$$\nabla^T f(x) \cdot \delta x < 0$$

Mivel

$$c(x + \delta x) \approx c(x) + \nabla^T c(x) \cdot \delta x,$$

ahhoz, hogy a megengedett tartományban maradjunk teljesülnie kell a

$$c(x) + \nabla^T c(x) \cdot \delta x \geq 0$$

feltételnek.

1. eset: ha  $c(x) > 0$ , akkor kellően kicsi  $\delta x$  esetén a fenti feltétel teljesül. Ekkor ha  $x$  minimumhely  $\nabla f(x) = 0$ .

2. eset: ha  $c(x) = 0$  (a feltétel aktív), akkor  $\nabla^T c(x) \cdot \delta x \geq 0$  kell, ami a  $\nabla^T f(x) \cdot \delta x < 0$  feltételellet egyszerre csak akkor nem teljesülhet, ha  $\nabla f(x)$  és  $\nabla c(x)$  ugyanabba az irányba mutat, azaz

$$\nabla f(x) = \lambda \nabla c(x), \quad \text{valamely } \lambda \geq 0 \text{ esetén}$$

Ez utóbbi feltétel azt jelenti, hogy ha  $x^*$  lokális minimumhely, akkor valamely  $\lambda^* \geq 0$  esetén

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = 0,$$

(KKT 1. és 4. feltétel.)

és

$$\lambda^* c(x^*) = 0,$$

(KKT 5. feltétel.)

továbbá teljesül a korlátozó feltétel:

$$c(x^*) \geq 0$$

(KKT 3. feltétel)

## A LICQ feltételek

Egy példa arra, hogy ha a minimumhelyen a feltételfüggvények gradiensei párhuzamosak, akkor a KKT feltételek nem feltétlenül teljesülnek.

Keresett az

$$f(x) = x_1 + x_2 + x_3^2$$

minimuma az

$$c_1(x) = x_1 - 1 = 0, \quad c_2(x) = x_1^2 + x_2^2 - 1 = 0$$

feltételek mellett.

A megoldás az  $x^* = (1, 0, 0)$  pont, ebben a pontban

$$\nabla c_1(x^*) = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad \nabla c_2(x^*) = \begin{pmatrix} 2x_1 \\ 2x_2 \\ 0 \end{pmatrix}$$

és

$$\frac{\partial \mathcal{L}}{\partial x_2}(x^*, \lambda^*) = 1$$

tetszőleges  $\lambda^*$  esetén.

## Példa

Határozza meg az

$$f(x) = x_1^2 + 3x_1x_2 + x_2^2 - x_1 + x_2$$

függvény minimumhelyét az

$$x_1^2 + x_2^2 = \frac{1}{9}$$

feltétel mellett.

A Lagrange-függvény:

$$\mathcal{L}(x, \lambda) = x_1^2 + 3x_1x_2 + x_2^2 - x_1 + x_2 - \lambda(x_1^2 + x_2^2 - \frac{1}{9})$$

$$\frac{\partial \mathcal{L}}{\partial x_1} = 2x_1 + 3x_2 - 1 - 2\lambda x_1 = 0$$

$$\frac{\partial \mathcal{L}}{\partial x_2} = 3x_1 + 2x_2 + 1 - 2\lambda x_2 = 0$$

Az előző két egyenletet összeadva és rendezve:

$$(x_1 + x_2)(5 - 2\lambda) = 0$$

1. eset: ha  $x_1 = -x_2$ , akkor a korlátozó feltételekből

$$\begin{aligned}2x_1^2 &= \frac{1}{9} \\x_1^2 &= \frac{1}{18} \\x_1 &= \pm \frac{1}{3\sqrt{2}}\end{aligned}$$

A lehetséges pontok:

$$\left(\frac{1}{3\sqrt{2}}, -\frac{1}{3\sqrt{2}}\right), \quad \left(-\frac{1}{3\sqrt{2}}, \frac{1}{3\sqrt{2}}\right)$$

2. eset: ha  $\lambda = \frac{5}{2}$ , akkor  $\frac{\partial \mathcal{L}}{\partial x_1} = 0$ -ból

$$-3x_1 + 3x_2 = 1$$

$$x_2 = \frac{1}{3} + x_1$$


Ezt a korlátrozó feltételbe visszahelyettesítve:

$$x_1^2 + \frac{1}{9} + \frac{2}{3}x_1 + x_1^2 - \frac{1}{9} = 0$$


$$2x_1(x_1 + \frac{1}{3}) = 0$$

A lehetséges pontok:

$$\left(0, \frac{1}{3}\right), \quad \left(-\frac{1}{3}, 0\right)$$



Az  $f(x) = x_1^2 + 3x_1x_2 + x_2^2 - x_1 + x_2$  függvény



Az  $f(x) = x_1^2 + 3x_1x_2 + x_2^2 - x_1 + x_2$  függvény szintvonalaiból, a korlátozó feltétel és a 4 meghatározott pont.

## Példa

Határozza meg az

$$f(x) = (x_1 - 2)^2 + 2(x_2 - 1)^2$$

függvény minimumát az

$$x_1 + 4x_2 \leq 3$$

$$x_1 \geq x_2$$

korlátozó feltételek mellett.

A Lagrange-függvény:

$$\mathcal{L}(x, \lambda) = (x_1 - 2)^2 + 2(x_2 - 1)^2 - \lambda_1 \underbrace{(3 - x_1 - 4x_2)}_{c_1(x)} - \lambda_2 \underbrace{(x_1 - x_2)}_{c_2(x)}$$

A KKT feltételek:

$$\frac{\partial \mathcal{L}}{\partial x_1} = 0, \quad \frac{\partial \mathcal{L}}{\partial x_2} = 0, \quad \lambda_1(3 - x_1 - 4x_2) = 0, \quad \lambda_2(x_1 - x_2) = 0, \quad \lambda_1, \lambda_2 \geq 0$$

$$2(x_1 - 2) + \lambda_1 - \lambda_2 = 0 \quad (1)$$

$$4(x_2 - 1) + 4\lambda_1 + \lambda_2 = 0 \quad (2)$$

$$\lambda_1(3 - x_1 - 4x_2) = 0 \quad (3)$$

$$\lambda_2(x_1 - x_2) = 0 \quad (4)$$

$$\lambda_1, \lambda_2 \geq 0 \quad (5)$$

**1. eset:** ha  $\lambda_1 = \lambda_2 = 0$ , ekkor

(1), (2)  $\Rightarrow x_1 = 2, x_2 = 1$ , ami nem megengedett pont (a feltétel nélküli feladat megoldása)

**2. eset:** ha  $\lambda_1 = 0, \lambda_2 \neq 0$ , ekkor

$$(4) \Rightarrow x_1 = x_2$$

$$(1)+(2) \Rightarrow x_1 = x_2 = \frac{4}{3}$$

$$(1) \Rightarrow \lambda_2 = -\frac{4}{3}, \text{ ami ellentmond (5)-nek.}$$

$$2(x_1 - 2) + \lambda_1 - \lambda_2 = 0 \quad (1)$$

$$4(x_2 - 1) + 4\lambda_1 + \lambda_2 = 0 \quad (2)$$

$$\lambda_1(3 - x_1 - 4x_2) = 0 \quad (3)$$

$$\lambda_2(x_1 - x_2) = 0 \quad (4)$$

$$\lambda_1, \lambda_2 \geq 0 \quad (5)$$

**3. eset:** ha  $\lambda_1 \neq 0, \lambda_2 = 0$ , ekkor


$$(3) \implies 3 - x_1 - 4x_2 = 0,$$

$$(2)-4 \cdot (1) \implies x_1 = \frac{5}{3}, x_2 = \frac{1}{3}, \lambda_1 = \frac{2}{3}$$

**4. eset:** ha  $\lambda_1 \neq 0, \lambda_2 \neq 0$ , ekkor

$$(3), (4) \implies x_1 = x_2 \text{ és } 3 - x_1 - 4x_2 = 0 \implies x_1 = x_2 = \frac{3}{5}$$

$$(1), (2) \implies \lambda_1 = \frac{22}{25}, \lambda_2 = -\frac{48}{25}, \text{ ami ellentmond (5)-nek}$$



## Példa

Határozza meg az

$$f(x) = x_1^2 + x_2^2$$

függvény minimumhelyét az

$$x_1^2 + x_1 x_2 + x_2^2 = 3$$

feltétel mellett.

A Lagrange-függvény:

$$\mathcal{L}(x, \lambda) = x_1^2 + x_2^2 - \lambda(x_1^2 + x_1 x_2 + x_2^2 - 3)$$

$$\frac{\partial \mathcal{L}}{\partial x_1} = 2x_1 - \lambda(2x_1 + x_2) = 0$$

$$\frac{\partial \mathcal{L}}{\partial x_2} = 2x_2 - \lambda(2x_2 + x_1) = 0$$

Az előző két egyenletet összeadva és rendezve:

$$(x_1 + x_2)(2 - 3\lambda) = 0$$

1. eset: ha  $x_1 = -x_2$  , akkor a korlátozó feltételekből

$$x_1^2 = 3$$

$$x_1 = \pm\sqrt{3}$$

A lehetséges pontok:

$$\left(\sqrt{3}, -\sqrt{3}\right), \quad \left(-\sqrt{3}, \sqrt{3}\right)$$

2. eset: ha  $\lambda = \frac{2}{3}$ , akkor  $\frac{\partial \mathcal{L}}{\partial x_1} = 0$ -ból

$$2x_1 - \frac{2}{3}(2x_1 + x_2) = 0$$

$$x_1 = x_2$$


Ezt a korlátozó feltételbe visszahelyettesítve:

$$3x_1^2 = 3$$

$$x_1 = \pm 1$$

A lehetséges pontok:

$$(1, 1), \quad (-1, -1)$$



Az  $f(x) = x_1^2 + x_2^2$  függvény szintvonala, a korlátos feltétel és a 4 meghatározott pont.

## Példa

Határozza meg az

$$f(x) = (x_1 - 1)^2 + x_2 - 2$$


függvény minimumát az

$$x_1 + x_2 - 2 \leq 0, \quad (x_1 + 1)^2 + x_2^2 \leq 9$$

feltételek mellett.

Matlab-bal:

$$x_{opt} = \begin{pmatrix} 0.6661 \\ -2.4948 \end{pmatrix}, \quad f_{opt} = -4.3833, \quad \lambda = \begin{pmatrix} 5.2236 \cdot 10^{-9} \\ 0.2004 \end{pmatrix}$$



## Büntető függvények módszere

A feladat: keresett

$$\min_x f(x) \text{ ha } c_i(x) = 0, \quad i \in \mathcal{E},$$

ahol  $f$  és  $c_i$  kétszer folytonosan differenciálhatóak.

Legyen

$$\Phi(x) = 0 \text{ ha } x \text{ megengedett}$$

$$\Phi(x) > 0 \text{ egyébként,}$$

és

$$F(x, \alpha) = f(x) + \alpha\Phi(x),$$

ahol  $\alpha > 0$  a büntető paraméter.

Az új feladat („penalty problem”): keresett

$$\min_x F(x, \alpha_k)$$

az  $\alpha_k$  paraméterek valamelyen monoton növekvő, végtelenhez tartó sorozata esetén.

# Büntető függvények módszere

## Az algoritmus:

- ① Legyen  $k = 0$ ,  $\alpha_0 > 0$
- ② meghatározzuk a  $\min_x F(x, \alpha_k)$  feladat  $x_k$  megoldását.
- ③ ha  $x_k$  megengedett, akkor leállás
- ④ legyen  $\alpha_{k+1} > \alpha_k$
- ⑤ legyen  $k = k + 1$  és  $\rightarrow (2)$

tipikusan az  $\alpha_{k+1}$  értékét az  $[1.4\alpha_k, 10\alpha_k]$  intervallumból választjuk.

## Kvadratikus büntető tag

$$F(x, \alpha) = f(x) + \frac{\alpha}{2} \sum_{i \in \mathcal{E}} c_i(x)^2 = f(x) + \frac{\alpha}{2} c(x)^T c(x),$$

ahol  $c(x) = (c_1(x), \dots, c_{|\mathcal{E}|}(x))$ .

## Kvadratikus büntető tag

A módszer alkalmazható egyenlőtlenséggel adott korlátozó feltételek esetén is:

$$F(x, \alpha) = f(x) + \frac{\alpha}{2} \sum_{i \in \mathcal{E}} c_i(x)^2 + \frac{\alpha}{2} \sum_{i \in \mathcal{I}} (\max[0, -c_i(x)])^2$$

A feladat gyakran rosszul kondícionált: ha  $\alpha_k \rightarrow \infty$  akkor  $x^*(\alpha_k) \rightarrow x^*$ , de  $cond(\nabla_x^2 F(x, \alpha_k)) \rightarrow \infty$ .

# Belsőpontos módszerek

A feladat: keresett

$$\min_x f(x) \text{ ha } c_i(x) \geq 0, \quad i \in \mathcal{I},$$

ahol  $f$  és  $c_i$  kétszer folytonosan differenciálhatóak.

Az ötlet: használunk olyan büntető tagot, mely tart végtelenhez, ha  $x$  tart a "nem megengedett" állapothoz.

## Logaritmikus korlát

$$F(x, \alpha) = f(x) - \alpha \sum_{i \in I} \log c_i(x),$$

ahol  $\alpha > 0$ .

## Inverz korlát

$$F(x, \alpha) = f(x) + \alpha \sum_{i \in I} \frac{1}{c_i(x)},$$

ahol  $\alpha > 0$ .

# Megbízhatósági tartomány módszerek

- a célfüggvényt egy kvadratikus modellfüggvénytel helyettesítjük
- meghatározzuk a megbízhatósági tartományt
- ezen tartományon belül kiszámítjuk a köv. iteráltat

A megbízhatósági tartomány mérete

- túl kicsi → az algoritmus nem tud lényegi lépést tenni
- túl nagy → a célfüggvény és a modellfüggvény minimumhelye nagyon különbözheto

A modellfüggvény

$$f(x_k + p) \approx f_k + \nabla f_k^T p + \frac{1}{2} p^T \nabla^2 f_k p$$

$$m_k(p) = f_k + g_k^T p + \frac{1}{2} p^T B_k p,$$

ahol  $g_k = \nabla f_k$  és  $B_k \approx \nabla^2 f_k$ .

# Megbízhatósági tartomány módszerek

Az  $m_k(p)$  és  $f(x_k + p)$  közötti különbség

- $O(\|p\|^3)$  ha  $B_k = \nabla^2 f_k$  (megbízh. tart. Newton módszer)
- $O(\|p\|^2)$  egyébként

Az  $x_k \mapsto x_{k+1}$  lépés: keressük meg a

$$\min_p m_k(p) = \min_p (f_k + g_k^T p + \frac{1}{2} p^T B_k p), \text{ ahol } \|p\| \leq \Delta_k$$

feladat megoldását. (Feltételes optimalizálás.)

Ha  $B_k$  pozitív definit és  $\|B_k^{-1} g_k\| \leq \Delta_k$  akkor  $p_k = B_k^{-1} g_k$  az egzakt minimumhely (teljes lépés, a feltétel inaktív).

# Megbízhatósági tartomány módszerek

A megbízhatósági tartomány  $\Delta_k$  sugarának megválasztása:

$$\varrho_k = \frac{f(x_k) - f(x_k + p)}{m(0) - m(p)}$$

- ha  $\varrho_k < 0$  akkor  $f(x_k + p) > f(x_k)$ , elvetjük a lépést
- ha  $\varrho_k \approx 1$  akkor a modell jól közelíti  $f$ -et, a köv lépéssben megnöveljük a tartományt
- ha  $\varrho_k > 0$  de  $\varrho_k << 1$  akkor a köv lépéssben ugyanezt a sugarat használjuk
- ha  $\varrho_k \approx 0$  akkor a köv lépéssben csökkentjük a sugarat

Adottak  $\hat{\Delta} > 0$ ,  $\Delta_0 \in (0, \hat{\Delta})$ ,  $\eta \in [0, 0.25)$

**for**  $k = 0, 1, 2, \dots$

    meghatározzuk  $p_k$ -t

    kiszámítjuk  $\varrho_k$ -t

**if**  $\varrho_k < \frac{1}{4}$

$\Delta_{k+1} = \frac{1}{4}\Delta_k$

**else**

**if**  $\varrho_k > \frac{3}{4}$  and  $\|p_k\| = \Delta_k$

$\Delta_{k+1} = \min(2\Delta_k, \hat{\Delta})$

**else**

$\Delta_{k+1} = \Delta_k$

**end**

**end**

**if**  $\varrho_k > \eta$

$x_{k+1} = x_k + p_k$

**else**

$x_{k+1} = x_k$

**end**

## Tétel

A  $p^*$  vektor pontosan akkor oldja meg a

$$\min_p m(p) = \min_p (f + g^T p + \frac{1}{2} p^T B p), \text{ ahol } \|p\| \leq \Delta$$

feladatot, ha létezik olyan  $\lambda \geq 0$  konstans, hogy

$$(B + \lambda I)p^* = -g$$

$$\lambda(\Delta - \|p^*\|) = 0$$

és  $(B + \lambda I)$  pozitív definit.

**Megjegyzés.** Ha  $\Delta$  olyan, hogy  $\|p^*\| < \Delta$ , akkor  $\lambda = 0$ ,  $Bp^* = -g$  és  $B$  poz.def. Ha  $p^*$  a tartomány peremén van, akkor  $\lambda$  pozitív is lehet, és  $\lambda p^* = -Bp^* - g = -\nabla m(p^*)$  (azaz  $p^*$  párhuzamos az  $m$  negatív gradiensével).

A

$$\min_p m(p) = \min_p (f + g^T p + \frac{1}{2} p^T B p), \text{ ahol } \|p\| \leq \Delta$$

problémának általában egy közelítő megoldását keressük meg, amely a modellfv-ben legalább akkora csökkenést eredményez, mint a Cauchy-pont.

**Cauchy-pont:** a modellfüggvény minimumhelye a negatív gradiens irányában, a megbízhatósági tartományon belül.

$$p_k^C = -\tau_k \frac{\Delta_k}{\|g_k\|} g_k$$

$$\tau_k = \begin{cases} 1 & \text{ha } g_k^T B_k g_k \leq 0 \\ \min \left( \frac{\|g_k\|^3}{\Delta_k g_k^T B_k g_k}, 1 \right) & \text{egyébként} \end{cases}$$

## A Powel-féle dogleg módszer

Ha  $B$  pozitív definit, akkor  $p^B = -B^{-1}g$  az  $m_k$  feltétel nélküli minimumhelye.

Legyen  $p^U$  a legmeredekebb csökkenés irányában a minimumhely:

$$p^U = -\frac{g^T g}{g^T B g} g,$$


és legyen

$$\tilde{p}(\tau) = \begin{cases} \tau p^U, & 0 \leq \tau \leq 1 \\ p^U + (\tau - 1)(p^B - p^U), & 1 < \tau \leq 2 \end{cases}$$

$p_k$ : az  $m_k$  minimumhelye a  $\tilde{p}(\tau)$  görbe mentén, a tartományon belül.

Ha  $\|p^B\| < \Delta_k$  akkor  $p_k = p^B$ , egyébként  $p_k$  a tartomány határvonalának és a "dogleg" görbünek a metszéspontja.

# A dogleg módszer



## Konjugált gradiens módszer lineáris esetben

Ha  $A$  szimmetrikus és pozitív definit, akkor az

$$Ax = b$$

lineáris egyenletrendszer megoldása ekvivalens a

$$\Phi(x) = \frac{1}{2}x^T Ax - b^T x$$

kvadratikus fv minimumhelyének megkeresésével, továbbá

$$r(x) := Ax - b = \nabla\Phi(x)$$

Jelölés:  $r_k = r(x_k)$ .

## Konjugált vektorok

Legyen  $A$  egy szimmetrikus, pozitív definit mátrix. A  $p_1, \dots, p_m$  nem nulla vektorokat  $A$ -konjugáltaknak nevezzük, ha

$$p_i^T A p_j = 0, \quad \forall i \neq j \text{ esetén.}$$

**Megjegyzés.** Az  $A$ -konjugált vektorok lineárisan függetlenek.

### Konjugált irányok módszere:

Adott  $A \in \mathbb{R}^{n \times n}$ ,  $x_0 \in \mathbb{R}^n$  és  $p_0, \dots, p_{n-1}$   $A$ -konjugált vektorok esetén

$$x_{k+1} = x_k + \alpha_k p_k,$$

ahol  $\alpha_k$  a  $\alpha \mapsto \Phi(x_k + \alpha p_k)$  minimumhelye:

$$\alpha_k = -\frac{r_k^T p_k}{p_k^T A p_k}$$

## Tétel

Tetszőleges  $x_0 \in \mathbb{R}^n$  esetén az előbb definiált konjugált irányok módszere legfeljebb  $n$  lépés után megáll az  $Ax = b$  egyenletrendszer  $x^*$  gyökével.

**Megjegyzés.** A konjugált irányok módszere esetén

$$r_k^T p_i = 0, \quad i = 0, 1, \dots, k-1,$$

azaz a  $k$ -adik maradékvektor ortogonális az összes korábbi irányra, továbbá  $x_k$  a  $\Phi$  minimumhelye az

$$\{x_0 + \text{span}\{p_0, p_1, \dots, p_{k-1}\}\}$$

halmaz fölött.

## Konjugált gradiens módszer lineáris esetben

**Konjugált gradiens módszer:** konjugált irányok módszere, speciális irányválasztással.

Legyen  $p_k$  a legmeredekebb csökkenési irány  $(-r_k)$  és az előző irány lineáris kombinációja,

$$p_k = -r_k + \beta_k p_{k-1},$$

úgy, hogy  $p_k$  és  $p_{k-1}$  A-konjugáltak legyenek:


$$\beta_k = \frac{r_k^T A p_{k-1}}{p_{k-1}^T A p_{k-1}}.$$

$$p_0 := -r_0 = b - Ax_0.$$



**Megjegyzés:**  $p_k$  meghatározásához csak az utolsó irány szükséges, ennek ellenére  $p_k$  az összes korábbi iránnyal A-konjugált lesz.

## Példa

$$A = \begin{pmatrix} 4 & 2 \\ 2 & 6 \end{pmatrix}, \quad b = \begin{pmatrix} 3 \\ 2 \end{pmatrix}, \quad x_0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$



# Gradiens vs konjugált gradiens



$$A = \begin{pmatrix} 10 & 0 \\ 0 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad x_0 = \begin{pmatrix} 10 \\ 1 \end{pmatrix}$$

# Konjugált gradiens módszer lineáris esetben

## Első verzió

Adott  $x_0$  esetén legyen  $r_0 = Ax_0 - b$ ,  $p_0 = -r_0$ ,  $k = 0$ .

**while**  $r_k \neq 0$

$$\alpha_k = -\frac{r_k^T p_k}{p_k^T A p_k}$$

$$x_{k+1} = x_k + \alpha_k p_k$$

$$r_{k+1} = Ax_{k+1} - b$$

$$\beta_{k+1} = \frac{r_{k+1}^T A p_k}{p_k^T A p_k}$$

$$p_{k+1} = -r_{k+1} + \beta_{k+1} p_k$$

$$k = k + 1$$

**end**

## Tétel.

Az előbb definiált sorozat legfeljebb  $n$  lépéssben eléri  $x^*$ -ot.

# Konjugált gradiens módszer lineáris esetben

## Javított verzió

Adott  $x_0$  esetén legyen  $r_0 = Ax_0 - b$ ,  $p_0 = -r_0$ ,  $k = 0$ .

**while**  $r_k \neq 0$

$$\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$$

$$x_{k+1} = x_k + \alpha_k p_k$$

$$r_{k+1} = r_k + \alpha_k A p_k$$

$$\beta_{k+1} = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$$

$$p_{k+1} = -r_{k+1} + \beta_{k+1} p_k$$

$$k = k + 1$$

**end**

**Megjegyzés.** Műveletigény: minden lépésben egy mátrix-vektor szorzást és két belsőszorzat kiszámítását kell elvégezni.

Az iteráció során az  $A$  nem változik (nincs feltöltődés).

→ jól használható nagyméretű **ritka mátrixok** esetén

# Ritka mátrixok

- Ritka mátrix: elemeinek jelentős hányada 0
- Csak a nemnulla elemeket tárolva és azokkal számolva jelentősen csökkenthető a tár-, és műveletigény.
- A nemnulla elemek elhelyezkedése lehet jól strukturált (pl. tridiagonális mátrix), de nem feltétlenül az

Legyen  $A \in \mathbb{R}^{n \times n}$  és jelölje  $nnz$  a nemnulla elemek számát.

Ritka mátrixok tárolására sok mód ismert, a leggyakoribbak:

# Ritka mátrixok, koordinátánkénti tárolás

Minden  $a_{ij} \neq 0$  elem esetén a  $(i, j, a_{ij})$  számhármast tároljuk.

3 tömb: sor, oszlop, ertek, mindenhez  $nnz$  elemű.

Jellemzői:

- könnyen áttekinthető
- könnyen hozzávehető egy újabb nem nulla elem
- a nem nulla elemek sorrendje tetszőleges
- sor- és oszlopindex szerint is könnyen kereshetőek az elemek
- tárigény:  $2nnz$  egész és  $nnz$  lebegőpontos szám
- a mátrix-vektor szorzás egyszerűen végezhető

# Ritka mátrixok, koordinátánkénti tárolás

## Példa

$$A = \begin{pmatrix} 0.5 & 0 & 0 & -2.1 & 0 \\ 0 & 0.1 & 3.2 & 0 & 0 \\ 0 & -1.7 & 3 & 0 & 0 \\ 0 & 0 & 0 & -1 & 0 \\ 3.1 & 0 & 0 & 0 & 1.4 \end{pmatrix}$$

érték	0.5	-2.1	0.1	3.2	-1.7	3	-1	3.1	1.4
sor	1	1	2	2	3	3	4	5	5
oszlop	1	4	2	3	2	3	4	1	5

## Mátrix-vektor szorzás

Legyen  $A \in \mathbb{R}^{n \times n}$  egy ritka mátrix,  $x \in \mathbb{R}^n$  egy telt vektor.  $y = Ax$  számítása:

```
for k=1:n  
    y(sor(k))=y(sor(k))+érték(k)*x(oszlop(k));  
end
```

# Ritka mátrixok, Compressed Row Storage

3 tömb: ertek ( $nnz$  elemű), oszlop ( $nnz$  elemű), sor ( $n + 1$  elemű)

ertek: a nemnulla elemek, sorfolytonosan

oszlop: a nemnulla elemek oszlopindexei

sor: az első  $n$  eleme megmutatja, hogy az ertek tömb mely elemeinél kezdődik új sor, az utolsó eleme  $nnz + 1$

## Példa

$$A = \begin{pmatrix} 0.5 & 0 & 0 & -2.1 & 0 \\ 0 & 0.1 & 3.2 & 0 & 0 \\ 0 & -1.7 & 3 & 0 & 0 \\ 0 & 0 & 0 & -1 & 0 \\ 3.1 & 0 & 0 & 0 & 1.4 \end{pmatrix}$$

ertek	0.5	-2.1	0.1	3.2	-1.7	3	-1	3.1	1.4
oszlop	1	4	2	3	2	3	4	1	5

sor	1	3	5	7	8	10
-----	---	---	---	---	---	----

# Ritka mátrixok, Compressed Row Storage

Jellemzői:

- a sorok szerinti elérés egyszerű, az oszlopok szerinti bonyolult
- az elemek sorrendje nem tetszőleges
- tárigény:  $nnz$  lebegőpontos szám,  $nnz + n + 1$  egész
- a mátrix-vektor szorzás egyszerű

## Mátrix-vektor szorzás

Legyen  $A \in \mathbb{R}^{n \times n}$  egy ritka mátrix,  $x \in \mathbb{R}^n$  egy telt vektor.  $y = Ax$  számítása:

```
for i=1:n
    y(i)=0;
    for k=sor(i):sor(i+1)-1
        y(i)=y(i)+ertek(k)*x(oszlop(k));
    end
end
```

## Compressed Column Storage (Harwell-Boeing formátum)

3 tömb: ertek ( $nnz$  elemű), sor ( $nnz$  elemű), oszlop ( $n + 1$  elemű)

ertek: a nemnulla elemek, oszlopfolytonosan

sor: a nemnulla elemek sorindexei

oszlop: az első  $n$  eleme megmutatja, hogy az ertek tömb mely elemeinél kezdődik új oszlop, az utolsó eleme  $nnz + 1$

Az  $A$  mátrix CCS formátuma nem más, mint az  $A^T$  mátrix CRS formátuma.

# Ritka mátrixok, Compressed Column Storage

## Példa

$$A = \begin{pmatrix} 0.5 & 0 & 0 & -2.1 & 0 \\ 0 & 0.1 & 3.2 & 0 & 0 \\ 0 & -1.7 & 3 & 0 & 0 \\ 0 & 0 & 0 & -1 & 0 \\ 3.1 & 0 & 0 & 0 & 1.4 \end{pmatrix}$$

ertek	0.5	3.1	0.1	-1.7	3.2	3	-2.1	-1	1.4
sor	1	5	2	3	2	3	1	4	5

oszlop	1	3	5	7	9	10
--------	---	---	---	---	---	----

# Ritka mátrixok, Compressed Column Storage

## Mátrix-vektor szorzás

Legyen  $A \in \mathbb{R}^{n \times n}$  egy ritka mátrix,  $x \in \mathbb{R}^n$  egy telt vektor.  $y = x^T \cdot A$  számítása:

```
for j=1:n
    y(j)=0;
    for k=oszlop(j):oszlop(j+1)-1
        y(j)=y(j)+ertek(k)*x(sor(k));
    end
end
```


# Konjugált gradiens módszer, lineáris eset

## Tétel.

Ha  $A$ -nak  $r$  különböző sajátértéke van, akkor a módszer legfeljebb  $r$  lépéssben megtalálja  $x^*$ -ot.

Ha  $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ , akkor

$$\|x_{k+1} - x^*\|_A \leq \left( \frac{\lambda_{n-k} - \lambda_1}{\lambda_{n-k} + \lambda_1} \right) \|x_0 - x^*\|_A$$



# Konjugált gradiens módszer, lineáris eset

## Prekondícionálás.

Legyen  $C$  egy reguláris mátrix. Az  $\hat{x} = Cx$  transzformációt alkalmazva a megoldandó egyenletrendszer

$$(C^{-T}AC^{-1})\hat{x} = C^{-T}b,$$

a minimalizálandó függvény

$$\frac{1}{2}\hat{x}^T(C^{-T}AC^{-1})\hat{x} - (C^{-T}b)\hat{x}$$

alakú lesz.

Ha a  $(C^{-T}AC^{-1})$  mátrix sajátértékeinek eloszlása jobb, akkor a konvergencia gyorsabb lesz.

## Konjugált gradiens módszer, lineáris eset

Valójában az algoritmusban nem a  $C$ , hanem a  $C^T C =: M$  mátrixra van szükség

Adott  $x_0$  és  $M$ . Legyen  $r_0 = Ax_0 - b$ .

Oldjuk meg az  $My_0 = r_0$  lin.egy.rendszert.

Legyenek  $p_0 = -y_0$ ,  $k = 0$ .

**while**  $r_k \neq 0$

$$\alpha_k = \frac{r_k^T y_k}{p_k^T A p_k}$$

$$x_{k+1} = x_k + \alpha_k p_k$$

$$r_{k+1} = r_k + \alpha_k A p_k$$

Oldjuk meg az  $My_{k+1} = r_{k+1}$  lin.egy.rendszert

$$\beta_{k+1} = \frac{r_{k+1}^T y_{k+1}}{r_k^T y_k}$$

$$p_{k+1} = -y_{k+1} + \beta_{k+1} p_k$$

$$k = k + 1$$

**end**

# Konjugált gradiens módszer, lineáris eset

## A prekondícionáló mátrix megválasztása

Ha pl  $A$  nagyméretű ritka mátrix, akkor egy lehetséges megoldás:

Legyen  $\widetilde{L}\widetilde{L}^T$  az  $A$  mátrix nem teljes Cholesky felbontása (akkor  $A \approx \widetilde{L}\widetilde{L}^T$ ),  
és legyen

$$M = \widetilde{L}\widetilde{L}^T.$$

Ekkor

$$C^{-T}AC^{-1} = \widetilde{L}^{-1}A\widetilde{L}^{-T} \approx I,$$

amely mátrixnak kedvező a sajátértékeloszlása.

## Példa.

Matlab-bal generálva:

- $A$ : egy  $25 \times 25$ -ös szimmetrikus, pozitív definit véletlen mátrix, melynek sajátértékei  $1, \dots, 25$  (ld. a beépített sprandsym függvényt),
- $x \in \mathbb{R}^{25}$  azonosan 1 oszlopvektor
- $b = Ax$  vektor,

a beépített pcg függvénnnyel ( $A$ -ra és  $b$ -re), az elvégzett lépések száma általában 20.

Ugyanez prekondicionálás után (az ichol függvényel elkészítve a nem teljes Cholesky-felbontás  $L$  mátrixát, illetve a prekondicionáló  $M = LL^T$  mátrixot):

az elvégzett lépések száma 4.

# Konjugált gradiens módszer, nemlineáris eset

	Lineáris eset	Nemlineáris eset
célfv	konvex kvadratikus	tetsz. nemlineáris
$\alpha_k$	egzakt min.	közeliítő min.
$r_k$	$Ax_k - b$ ( $= \nabla\Phi$ )	$\nabla f_k$

## Fletcher-Reeves algoritmus

Adott  $x_0$  esetén legyen  $p_0 = -\nabla f_0$ ,  $k = 0$ .

**while**  $\nabla f_k \neq 0$

$\alpha_k$  meghatározása

$$x_{k+1} = x_k + \alpha_k p_k$$

$\nabla f_{k+1}$  kiszámítása

$$\beta_{k+1} = \frac{\nabla f_{k+1}^T \nabla f_{k+1}}{\nabla f_k^T \nabla f_k}$$

$$p_{k+1} = -\nabla f_{k+1} + \beta_{k+1} p_k$$

$$k = k + 1$$

**end**

# Fletcher-Reeves algoritmus

## $\alpha$ meghatározása

$\alpha_k$ -t úgy választjuk, hogy  $p_{k+1}$  csökkenési irány legyen:

- $\alpha_k$  vagy az egzakt minimumhely,
- ha  $\alpha_k$  nem egzakt minimumhely, akkor teljesítse az erős Wolfe-feltételeket:

$$f(x_k + \alpha_k p_k) \leq f(x_k) + c_1 \alpha_k \nabla f_k^T p_k$$

$$|\nabla f(x_k + \alpha_k p_k)^T p_k| \leq -c_2 \nabla f_k^T p_k$$

valamely  $0 < c_1 < c_2 < \frac{1}{2}$  esetén.

**Megjegyzés.** Az első feltétel a következő alakba írható

$$\Phi(\alpha_k) \leq \Phi(0) + c_1 \alpha_k \Phi'(0)$$

ahol  $\Phi(\alpha_k) = f(x_k + \alpha_k p_k)$ .

## $\alpha_k$ meghatározása, interpolációs módszer

Legyen adott  $a_0$  ( $\alpha_k$  kezdeti közelítése). Ha

$$\Phi(a_0) \leq \Phi(0) + c_1 a_0 \Phi'(0)$$

akkor  $\alpha_k = a_0$ . Egyébként meghatározzuk a  $\Phi(0)$ ,  $\Phi'(0)$ ,  $\Phi(a_0)$  értékekre illeszkedő másodfokú polinomot, és megkeressük a minimumhelyét ( $a_1$ ).

Ha

$$\Phi(a_1) \leq \Phi(0) + c_1 a_1 \Phi'(0)$$

akkor  $\alpha_k = a_1$ . Egyébként meghatározzuk a  $\Phi(0)$ ,  $\Phi'(0)$ ,  $\Phi(a_0)$ ,  $\Phi(a_1)$  értékekre illeszkedő harmadfokú polinomot, és megkeressük a minimumhelyét ( $a_2$ ). Ekkor  $0 < a_2 < a_1$ . Ha

$$\Phi(a_2) \leq \Phi(0) + c_1 a_2 \Phi'(0)$$

akkor  $\alpha_k = a_2$ , egyébként meghatározzuk a  $\Phi(0)$ ,  $\Phi'(0)$  értékekre és az utolsó két  $a_i$ -hez tartozó függvényértékre illeszkedő harmadfokú polinomot, stb.

# Konjugált gradiens módszer, nemlineáris eset

## Az algoritmus újraindítása

Minden elvégzett  $n$  lépés után javasolt újraindítani az iterációt  $\beta_k = 0$ -val.

Ekkor

$$\|x_{k+n} - x^*\| = O(\|x_k - x^*\|^2)$$

azaz a konvergencia “ $n$ -lépéses négyzetes”.

Ha  $f$  az  $x^*$  egy környezetében kvadratikus, és az iteráció konvergens, akkor elegendően nagy  $k$ -ra az iteráció belép ebbe a régióba. Ekkor az újraindítás a lineáris konjugált gradiens módszer használatát jelenti (ami legfeljebb  $n$  lépés után megáll).

# Nagyméretű feladatok

- akár több ezer változó
- tárolási problémák
- nagy műveletigény

# Nagyméretű feladatok

## Nem egzakt Newton-módszerek

Emlékeztető: Newton-módszer esetén a keresési irány meghatározása:

$$\nabla^2 f_k p_k = -\nabla f_k$$

Ha Cholesky-felbontással oldjuk meg, akkor az esetlegesen ritka Hesse-mátrix feltöltődhet.

*Konjugált gradiens módszer?*

A maradékvektor:  $r_k = \nabla^2 f_k p_k + \nabla f_k$

A keresést akkor fogjuk leállítani, ha

$$\|r_k\| \leq \eta_k \|\nabla f_k\|,$$

ahol  $0 < \eta_k < 1$ .

# Nem egzakt Newton-módszerek

## 1. Tétel

Tehát az  $x^*$  minimumhely egy környezetében a Hesse-mátrix létezik és folytonos, továbbá  $\nabla^2 f_* > 0$ . Ha az  $x_{k+1} = x_k + p_k$  iteráció esetén  $p_k$ -t úgy választottuk, hogy

$$\|r_k\| \leq \eta_k \|\nabla f_k\|,$$

ahol  $0 < \eta_k \leq \eta < 1$ , és  $x_0$  elegendően közel volt  $x^*$ -hoz, akkor  $x_k \rightarrow x^*$ .

## 2. Tétel

Az előző feltételek mellett a konvergencia szuperlineáris, ha  $\eta_k \rightarrow 0$ . Ha ráadásul  $\nabla f$  Lipschitz-folytonos  $x^*$  egy környezetében, és  $\eta_k = O(\|\nabla f_k\|)$ , akkor a konvergencia kvadratikus.

## Megjegyzés.

- $\eta_k = \min(0.5, \sqrt{\|\nabla f_k\|}) \rightarrow$  szuperlináris konvergencia
- $\eta_k = \min(0.5, \|\nabla f_k\|) \rightarrow$  kvadratikus konvergencia

## Nem egzakt Newton-módszerek

### Newton-módszer vonalmenti kereséssel + konjugált gradiens

A keresési irány meghatározásához a

$$\nabla^2 f_k p_k = -\nabla f_k$$

egyenletre alkalmazzuk a konjugált gradiens módszert, az előző leállási feltételellet.

Ha kiderül, hogy  $\nabla^2 f_k$  nem pozitív definit, vagy az irány nem csökkenési irány, akkor leállítjuk a konjugált gradiens algoritmust, a keresési irány a negatív gradiens lesz.

Előnye: jól alkalmazható nagy rendszerekre

Hátránya: ha a Hesse közel szinguláris, akkor a vonalmenti keresés nagyon lassú

# Deriváltmentes módszerek

## Nelder-Mead algoritmus


Az alapötlet  $\mathbb{R}^2$ -ben:

Tekintsünk egy  $x_1$ ,  $x_2$  és  $x_3$  csúcsú kiinduló háromszöget, és tfh


$$f(x_1) \leq f(x_2) \leq f(x_3)$$

Töröljük a legrosszabb pontot ( $x_3$ ) és vegyünk helyette egy új pontot a következő algoritmus szerint:


Tükrözük  $x_3$ -at az  $[x_1, x_2]$  szakasz középpontjára. legyen a kapott pont  $x_{N1}$




- Ha  $f(x_1) \leq f(x_{N1}) < f(x_2)$ , akkor legyen  $x_3 = x_{N1}$ . (**tükörözés**)  
(Az új pont nem a legrosszabb, de nem is jobb, mint az előző legjobb)
- Ha  $f(x_{N1}) < f(x_1)$  (az új pont jobb, mint az előző legjobb) akkor vegyük  $x_{N2}$ -t és
  - ▶ ha  $f(x_{N2}) < f(x_{N1})$  akkor legyen  $x_3 = x_{N2}$  (**nyújtás**)
  - ▶ egyébként legyen  $x_3 = x_{N1}$ .



- Ha  $f(x_{N1}) \geq f(x_2)$  (az új pont a legrosszabb)
  - ▶ ha  $f(x_2) \leq f(x_{N1}) < f(x_3)$  akkor vegyük  $x_{N1/2}$ -t (**kontrakció kifelé**) és ha  $f(x_{N1/2}) \leq f(x_{N1})$  akkor  $x_3 = x_{N1/2}$ .
  - ▶ egyébként vegyük  $x_{N-1/2}$ -t (**kontrakció befelé**) és ha  $f(x_{N-1/2}) \leq f(x_3)$  akkor  $x_3 = x_{N-1/2}$ .
  - ▶ ha egyik kontrakció sem működik, akkor kicsinyítsük le a háromszöget a legjobb pont irányába ( $x_1$ ).



# Kicsinyítés



## Legkisebb négyzetes feladatok

$t_1, t_2, \dots, t_m$  (időpillanatok)

$y_1, y_2, \dots, y_m$  (megfigyelések)

$F(t, x)$ : adott modell az  $x \in \mathbb{R}^n$  ismeretlen paramétervektorral.

Azt a paramétervektort keressük, melyre

$$\frac{1}{2} \sum_{i=1}^m (F(t_i, x) - y_i)^2.$$

minimális. Tipikusan  $n \ll m$ .

### Általános alak:

Keressük a

$$f(x) = \frac{1}{2} \sum_{i=1}^m r_i^2(x)$$

minimumhelyét, ahol  $r_i(x) : \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $i = 1, \dots, m$ .

# Legkisebb négyzetes feladatok

Az  $r(x) = (r_1(x), \dots, r_m(x))^T$  jelölésekkel (ekkor  $r : \mathbb{R}^n \rightarrow \mathbb{R}^m$ )

$$f(x) = \frac{1}{2} \sum_{i=1}^m r_i^2(x) = \frac{1}{2} \|r(x)\|_2^2.$$

**Lineáris legkisebb négyzetes feladat:**  $r(x) = Ax - b$  valamely  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$  esetén. (Az  $F$  modell az  $x$  lineáris függvénye)

**Nemlineáris legkisebb négyzetes feladat:**  $r(x)$  egy tetszőleges nemlineáris függvénye  $x$ -nek. (Az  $F$  modell nemlineáris függvénye  $x$ -nek)

# Lineáris legkisebb négyzetek

A modell:

$$F(t) = \sum_{j=1}^n x_j \varphi_j(t),$$

ahol  $x_1, \dots, x_n$  ismeretlen paraméterek,  $\varphi_1(t), \dots, \varphi_n(t)$  adott függvények.

**Példa.**

1.  $n = 3$  és  $\varphi_1(t) \equiv 1$ ,  $\varphi_2(t) = \sin(\pi t)$ ,  $\varphi_3(t) = \cos(\pi t)$ :

$$F(t) = x_1 + x_2 \sin(\pi t) + x_3 \cos(\pi t)$$

2.  $\varphi_1(t) \equiv 1$ ,  $\varphi_2(t) = t$ , ...,  $\varphi_n(t) = t^{n-1}$ :

$$F(t) = x_1 + x_2 t + x_3 t^2 + \cdots + x_n t^{n-1}$$

# Lineáris legkisebb négyzetek

Legyen

$$A = \begin{pmatrix} \varphi_1(t_1) & \varphi_2(t_1) & \dots & \varphi_n(t_1) \\ \varphi_1(t_2) & \varphi_2(t_2) & \dots & \varphi_n(t_2) \\ \vdots & & & \\ \varphi_1(t_m) & \varphi_2(t_m) & \dots & \varphi_n(t_m) \end{pmatrix} \in \mathbb{R}^{m \times n},$$

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix} \in \mathbb{R}^m, \quad x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n,$$

Ekkor

$$Ax = \begin{pmatrix} F(t_1) \\ F(t_2) \\ \vdots \\ F(t_m) \end{pmatrix}$$

# Lineáris legkisebb négyzetek

A célfüggvény:

$$f(x) = \frac{1}{2} \sum_{i=1}^m (F(t_i) - y_i)^2 = \frac{1}{2} \|Ax - y\|_2^2$$

(Most  $r_i(x) = F(t_i) - y_i$  és  $r_i : \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $i = 1, \dots, m.$ )

Ha  $x^*$  az  $f$  minimumhelye, akkor  $\nabla f(x^*) = 0$ , azaz  $x^*$  az alábbi rendszer megoldása

$$\frac{\partial f(x)}{\partial x_k} = \sum_{i=1}^m \left( \sum_{j=1}^n x_j \varphi_j(t_i) - y_i \right) \varphi_k(t_i) = 0$$

$k = 1, \dots, n$

# Lineáris legkisebb négyzetek

Egy lineáris egyenletrendszerhez jutunk:

$$\sum_{j=1}^n x_j \underbrace{\sum_{i=1}^m \varphi_j(t_i) \varphi_k(t_i)}_{(A^T A)_{kj}} = \underbrace{\sum_{i=1}^m y_i \varphi_k(t_i)}_{(A^T y)_k}$$

$$\underbrace{\sum_{j=1}^n (A^T A)_{kj} x_j}_{(A^T A x)_k} = (A^T y)_k$$

Mátrixos alakban:

$$A^T A x = A^T y$$

## Gauss-féle normálegyenlet

# Lineáris legkisebb négyzetek

$$A^T A x = A^T y$$

- A normálegyenlet mindig megoldható.
- A megoldás  $f$  minimumhelye lesz.
- Ha az  $A$  oszlopvektorai lineárisan függetlenek, akkor a megoldás egyértelmű.
- Ha az  $A$  oszlopvektorai lineárisan függők ( $A^T A$  szinguláris), akkor végtelen sok megoldás van.

Szinguláris esetben

- végezzünk több mérést (növeljük  $m$ -et)
- egyszerűsítsük a modellt (csökkentsük  $n$ -et)


## 1. Példa.

Határozzuk meg az alábbi adatokat négyzetesen legjobban közelítő

$$F(t) = x_1 + x_2 \cos(\pi t) + x_3 \sin(\pi t)$$

alakú modellt!

$t_i$	0	$\frac{1}{2}$	1	$\frac{3}{2}$	2	$\frac{5}{2}$
$f_i$	1	-2	$-\frac{5}{2}$	$-\frac{1}{2}$	$\frac{5}{4}$	$-\frac{3}{2}$




$$\varphi_1(t) \equiv 1, \varphi_2(t) = \cos(\pi t), \varphi_3(t) = \sin(\pi t)$$

$$A = \begin{pmatrix} 1 & \cos(\pi t_1) & \sin(\pi t_1) \\ 1 & \cos(\pi t_2) & \sin(\pi t_2) \\ \vdots & & \\ 1 & \cos(\pi t_6) & \sin(\pi t_6) \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & -1 & 0 \\ 1 & 0 & -1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$$

$$A^T A = \begin{pmatrix} 6 & 1 & 1 \\ 1 & 3 & 0 \\ 1 & 0 & 3 \end{pmatrix}, \quad A^T f = \begin{pmatrix} -\frac{17}{4} \\ \frac{19}{4} \\ -3 \end{pmatrix}$$

Az  $A^T A x = A^T f$  Gauss-féle normálegyenlet megoldása:

$$x = \begin{pmatrix} -\frac{29}{32} \\ \frac{181}{96} \\ -\frac{67}{96} \end{pmatrix}$$



## 2. Példa.

Határozzuk meg az alábbi adatokat négyzetesen legjobban közelítő

$$F(t) = x_1 + x_2 \cos(\pi t) + x_3 \sin(\pi t)$$

alakú modellt!

$t_i$	0	$\frac{1}{2}$	2	$\frac{5}{2}$
$f_i$	1	-2	$\frac{5}{4}$	$-\frac{3}{2}$

Az előző példából:

$t_i$	0	$\frac{1}{2}$	1	$\frac{3}{2}$	2	$\frac{5}{2}$
$y_i$	1	-2	$-\frac{5}{2}$	$-\frac{1}{2}$	$\frac{5}{4}$	$-\frac{3}{2}$

$$\begin{pmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ \textcolor{red}{1} & \textcolor{red}{-1} & \textcolor{red}{0} \\ \textcolor{red}{1} & 0 & -1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix} \rightarrow A = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix},$$

$$\begin{pmatrix} 1 \\ -2 \\ -\frac{5}{2} \\ -\frac{1}{2} \\ \frac{5}{4} \\ -\frac{3}{2} \end{pmatrix} \rightarrow y = \begin{pmatrix} 1 \\ -2 \\ \frac{5}{4} \\ -\frac{3}{2} \end{pmatrix}$$

Az  $A$  oszlopai lineárisan függőek  $\rightarrow A^T A$  szinguláris

A szingularitás kezelése:

1. több adat felvétele (ld. előző példa)
2. a modell egyszerűsítése:


$$F(t) = x_1 + x_2 \cos(\pi t)$$

Ekkor

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 0 \\ 1 & 1 \\ 1 & 0 \end{pmatrix}, \quad f = \begin{pmatrix} 1 \\ -2 \\ \frac{5}{4} \\ -\frac{3}{2} \end{pmatrix}$$

Az  $A^T A x = A^T f$  Gauss-féle normálegyenlet megoldása:

$$x = \begin{pmatrix} -1.3333 \\ 2.2333 \end{pmatrix}$$



# Lineáris legkisebb négyzetek

**Megoldási technikák az  $A^T A x = A^T y$  normálegyenlet esetén.**

(1)  $A^T A$  szimmetrikus

(2)  $A^T A$  pozitív definit, ha  $A$  teljes rangú, egyébként pozitív szemidefinit

Megoldási módszerek:

- Cholesky-felbontás,  
ha  $A$  teljes rangú.

Hátránya:  $\text{cond}(A^T A) = (\text{cond}(A))^2$

- QR-felbontás

Legyen

$$AP = Q \begin{pmatrix} R \\ 0 \end{pmatrix} = (Q_1, Q_2) \begin{pmatrix} R \\ 0 \end{pmatrix} = Q_1 R,$$

akkor

$$\|Ax - y\|_2^2 = \|RP^T x - Q_1^T y\|_2^2 + \|Q_2^T y\|_2^2,$$

így  $x^* = PR^{-1}Q_1^T y$ .

# Lineáris legkisebb négyzetek

- SVD felbontás

$$A = U \begin{pmatrix} S \\ 0 \end{pmatrix} V^T = (U_1, U_2) \begin{pmatrix} S \\ 0 \end{pmatrix} V^T = U_1 S V^T$$

$$\|Ax - y\|_2^2 = \|SV^T x - U_1^T y\|_2^2 + \|U_2^T y\|_2^2$$

Ekkor

$$x^* = VS^{-1} U_1^T y = \sum_{i=1}^n \frac{u_i^T y}{\sigma_i} v_i.$$

Ha  $\sigma_i$  kicsi, akkor  $x^*$  érzékeny az  $y$  és az  $A$  perturbációjára.

Költséges, de érzékenységvizsgálatra használható.

## Pszeudoinverz

Legyen  $A = USV^T$  az  $A \in \mathbb{R}^{m \times n}$  mátrix szinguláris felbontása. Ekkor az az  $A$  (Moore-Penrose féle) pszeudoinverze:

$$A^+ = VS^+U^T,$$

ahol  $S^+ \in \mathbb{R}^{n \times m}$  egy diagonális mátrix,

$$s_{ii}^+ = \frac{1}{\sigma_i}, \quad i = 1, \dots, \text{rang}(A)$$

( $\sigma_i$  az  $A$   $i$ -edik szinguláris értéke).

- A pszeudoinverz minden mátrix esetén egyértelműen létezik.
- Ha  $A$  invertálható, akkor  $A^+ = A^{-1}$ .
- Ha az  $A$  oszlopai lineárisan függetlenek, akkor  $A^+ = (A^TA)^{-1}A^T$ .

Tekintsük az  $Ax = b$  lineáris egyenletrendszeret. Keressük ennek a megoldását általános értelemben, azaz oldjuk meg az

$$\|Ax - b\|_2 \rightarrow \min$$

feladatot. Ennek megoldását az

$$x^* = A^+b$$

vektor adja:

- Ha az  $Ax = b$  rendszer egyértelműen megoldható, akkor  $x^*$  ezt adja.
- Ha több megoldása létezik az  $Ax = b$  rendszernek, akkor a fenti képlet a legkisebb euklideszi normájút adja.
- Ha az  $Ax = b$  rendszer nem oldható meg, akkor  $x^*$  a legkisebb négyzetes értelemben vett megoldást adja, amennyiben az nem egyértelműen létezik, akkor a legkisebb euklideszi normájút.

## Lineáris legkisebb négyzetek, példa

Szabályos időlépésekkel megfigyelünk egy  $y(t)$  jelet, de átviteli probléma miatt néhány időpillanatban hiányzik a megfigyelés. Próbáljuk meg rekonstruálni a jelet!

$$y = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \end{pmatrix} \rightarrow \begin{pmatrix} y_1 \\ \textcolor{red}{y_2} \\ \textcolor{red}{y_3} \\ y_4 \\ y_5 \end{pmatrix} \rightarrow \begin{pmatrix} y_1 \\ \textcolor{red}{0} \\ \textcolor{red}{0} \\ y_4 \\ y_5 \end{pmatrix} \rightarrow \begin{pmatrix} y_1 \\ y_4 \\ y_5 \end{pmatrix} = x$$

$$Sy = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \end{pmatrix} = \begin{pmatrix} y_1 \\ y_4 \\ y_5 \end{pmatrix} = x$$

Ha  $y$  a teljes  $n$  pontos jel,  $x$  pedig a megfigyelt  $k$  pontos jel, akkor

$$x = Sy,$$

ahol a  $k \times n$ -es mintavételezési  $S$  mátrix az  $n \times n$ -es egységmátrix alkalmas sorainak elhagyásával kapható.

A kimonadó  $(n - k)$  pontos jel:

$$S_m y = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \end{pmatrix} = \begin{pmatrix} y_2 \\ y_3 \end{pmatrix} = z$$

Ekkor

$$\begin{aligned} S^T x + S_m^T z &= \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} y_1 \\ y_4 \\ y_5 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 1 & 0 \\ 0 & 1 \\ 0 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} y_2 \\ y_3 \end{pmatrix} \\ &= \begin{pmatrix} y_1 \\ 0 \\ 0 \\ y_4 \\ y_5 \end{pmatrix} + \begin{pmatrix} 0 \\ y_2 \\ y_3 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \end{pmatrix} = y \end{aligned}$$

$z$ -t keressük, úgy, hogy az  $y$  jel „elég sima” legyen.

Legyen  $D$  a másodrendű differencia mátrix:

$$D = \begin{pmatrix} 1 & -2 & 1 & & & \\ & 1 & -2 & 1 & & \\ & & \ddots & \ddots & & \\ & & & 1 & -2 & 1 \end{pmatrix},$$


akkor a

$$J(z) := \|Dy\|_2^2 = \|D(S^T x + S_m^T z)\|_2^2 = \|DS^T x + DS_m^T z\|_2^2$$


függvény minimumát keressük. A megoldást a

$$S_m D^T D S_m z = -S_m D^T D S^T x$$


normálegyenlet adja.



Egy eredetileg 201 pontos jelből 80 megfigyelés hiányzik.



A normálegyenlet megoldása után a 80 pontos jel.



A megfigyelt jel (kék) kiegészítve az előbb meghatározott 80 pontos jellet (piros).

## Lineáris legkisebb négyzetek, példa


Megfigyelünk egy  $y(n)$  folyamatot, mely egy háromlépéses autoregresszív folyamat, azaz

$$y(n) = \alpha_1 y(n-1) + \alpha_2 y(n-2) + \alpha_3 y(n-3) + \varepsilon(n), \quad n = 4, 5, \dots$$

ahol  $\varepsilon(n)$  egy véletlen zaj. A megfigyelések alapján becsüljük meg az  $\alpha_1, \alpha_2, \alpha_3$  paramétereket.

$$\begin{pmatrix} y(4) \\ y(5) \\ \vdots \\ y(N) \end{pmatrix} \approx \begin{pmatrix} y(3) & y(2) & y(1) \\ y(4) & y(3) & y(2) \\ \vdots & \vdots & \vdots \\ y(N-1) & y(N-2) & y(N-3) \end{pmatrix} \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{pmatrix}$$

⇒ legkisebb négyzetes közelítés



Egy folyamat 100 lépése (kék), illetve az első 80 tagból megbecsülve az  $\alpha_1, \alpha_2, \alpha_3$  együtthatókat, az utolsó 20 lépéstre kapott becslés (piros).

# Nemlineáris legkisebb négyzetek

## Gauss-Newton módszer

Példa.

$t_i$	15	46	74	105	135	166	196	227	258	288	319	349
$y_i$	-1.7	0.1	5.2	10.3	15.8	18.9	21.1	20.3	16.1	10.2	4.2	0.5

A modell:

$$F(t) = x_1 + x_2 \cdot \cos\left(2\pi \frac{t - x_3}{365}\right)$$

Ekkor

$$r(x_1, x_2, x_3) = \begin{pmatrix} x_1 + x_2 \cdot \cos\left(2\pi \frac{t_1 - x_3}{365}\right) \\ x_1 + x_2 \cdot \cos\left(2\pi \frac{t_2 - x_3}{365}\right) \\ \vdots \\ x_1 + x_2 \cdot \cos\left(2\pi \frac{t_{12} - x_3}{365}\right) \end{pmatrix} - \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_{12} \end{pmatrix},$$

és  $r : \mathbb{R}^3 \rightarrow \mathbb{R}^{12}$  nemlineáris függvénye  $x$ -nek.

# Nemlineáris legkisebb négyzetek

$$f(x) = \frac{1}{2} \sum_{i=1}^m r_i^2(x),$$

így

$$\nabla f(x) = \sum_{i=1}^m r_i(x) \nabla r_i(x) = J(x)^T r(x)$$

és

$$\nabla^2 f(x) = \underbrace{\sum_{i=1}^m \nabla r_i(x) \nabla r_i(x)^T}_{J(x)^T J(x)} + \sum_{i=1}^m r_i(x) \nabla^2 r_i(x),$$

ahol  $J$  az  $r$  Jacobi mátrixa.

## Nemlineáris legkisebb négyzetek

Ha  $f$ -et Newton-módszerrel minimalizáljuk:

$$\nabla^2 f_k p = -\nabla f_k$$

Felhasználva, hogy  $\nabla f(x) = J(x)^T r(x)$  és  $\nabla^2 f(x) \approx J(x)^T J(x)$  kapjuk, hogy

$$J_k^T J_k p = -J_k^T r_k$$

Ha  $J_k$  teljes rangú és  $\nabla f_k \neq 0$  akkor  $p$  csökkenési irány  $\rightarrow$  vonalmenti keresés.

A Gauss-Newton módszer egy másik származtatása:

$r(x_k + p) \approx r(x_k) + J_k p$ , így

$$f(x_k + p) = \frac{1}{2} \|r(x_k + p)\|^2 \approx \frac{1}{2} \|r(x_k) + J_k p\|^2$$

# Levenberg-Marquardt módszer

Egy megbízhatósági tartomány alapú módszer a legkisebb négyzetes feladat megoldására.

Felhasználva, hogy  $r(x_k + p) \approx J_k p + r_k$  (vagy  $\nabla^2 f_k \approx J_k^T J_k$ ) a

$$\min_p \frac{1}{2} \|J_k p + r_k\|^2, \quad \text{ahol } \|p\| \leq \Delta_k$$

problémát oldjuk meg.

A modellfüggvény:

$$m_k(p) = \frac{1}{2} p^T J_k^T J_k p + p^T J_k^T r_k + \frac{1}{2} \|r_k\|^2$$

Legyen  $p_k^{LM}$  a minimumfeladat megoldása.

# Levenberg-Marquardt módszer

Ha  $p_k^{GN}$  a

$$J_k^T J_k p_k = -J_k^T r_k$$

feladat olyan megoldása, melyre  $\|p_k^{GN}\| \leq \Delta_k$ , akkor  $p_k^{LM} = p_k^{GN}$ .  
Egyébként létezik olyan  $\lambda > 0$ , hogy  $\|p_k^{LM}\| = \Delta_k$  és

$$(J_k^T J_k + \lambda I) p_k^{LM} = -J_k^T r_k.$$

**Megjegyzés.** A  $(J^T J + \lambda I)p = -J^T r$  egyenlet a

$$\min_p \frac{1}{2} \left\| \begin{pmatrix} J \\ \sqrt{\lambda} I \end{pmatrix} p + \begin{pmatrix} r \\ 0 \end{pmatrix} \right\|^2$$

legkisebb négyzetes feladatra vonatkozó normálegyenlet.

# Levenberg-Marquardt módszer

## Tétel

A  $p^{LM}$  vektor pontosan akkor lesz a

$$\min_p \|Jp + r\|^2, \quad \text{ahol } \|p\| \leq \Delta$$

feladat megoldása, ha  $p^{LM}$  megengedett, és létezik olyan  $\lambda \geq 0$  hogy

$$(J^T J + \lambda I)p^{LM} = -J^T r,$$

$$\lambda(\Delta - \|p^{LM}\|) = 0.$$

# Levenberg-Marquardt módszer

## I. Algoritmus

Adoot  $p_k$ ,  $\lambda_k$ , számítsuk ki  $J_k$  és  $r_k$  értékét

- ha  $J_k^T J_k + \lambda_k I$  nem pozitív definit, akkor  $\lambda_k := 4\lambda_k$ , ismételjük, amíg poz.def. mátrixot nem kapunk.
- oldjuk meg a  $(J_k^T J_k + \lambda_k I)p = -J_k^T r_k$  egyenletet a  $\|p_k\| \leq \Delta_k$  feltétel mellett.
- számítsuk ki

$$\varrho_k = \frac{f(x_k) - f(x_k + p)}{m_k(0) - m_k(p)}$$

értékét.

ha  $\varrho_k < 0.25$  akkor  $\Delta_k = \|p_k\|/4$

ha  $\varrho_k > 0.75$  és  $\|p_k\| = \Delta_k$  akkor  $\Delta_k = 2\Delta_k$

- ha  $\varrho_k > 0$  akkor  $x_k = x_k + p_k$
- $k = k + 1$


## II. Algoritmus

Dogleg módszer

# Legkisebb négyzetes módszerek alkalmazásai

Megfigyelünk egy  $\varepsilon(t)$  ismeretlen zajjal terhelt  $x(t)$  jelet:

$$y = x + \varepsilon$$



Egy olyan lassan változó jelet keresünk, mely közel van az  $y$  megfigyelt jelhez:

$$\min_x \left( \|x - y\|^2 + \lambda \sum_{i=1}^{n-1} (x_i - x_{i-1})^2 \right),$$


ahol  $n$  a megfigyelések száma,  $\lambda$  egy paraméter.


Mátrixos alakban:

$$\min_x \left\| \begin{pmatrix} I \\ \sqrt{\lambda}D \end{pmatrix} x - \begin{pmatrix} y \\ 0 \end{pmatrix} \right\|^2,$$

ahol

$$D = \begin{pmatrix} 1 & -1 & 0 & \dots & 0 & 0 & 0 \\ 0 & 1 & -1 & \dots & 0 & 0 & 0 \\ \vdots & & & & & & \\ 0 & 0 & 0 & \dots & 1 & -1 & 0 \\ 0 & 0 & 0 & \dots & 0 & 1 & -1 \end{pmatrix} \in \mathbb{R}^{(n-1) \times n}$$





# Legkisebb négyzetes módszerek alkalmazásai

## Image deblurring

Legyen

$X$  az eredeti kép

$A$  torzítási mátrix (PSF)

$B$  a torzított kép

$x = X(:)$

$b = B(:)$

Az  $x$  egy közelítését keressük, amikor

$$b = Ax + e,$$

ahol  $b$  és  $A$  ismertek, de az  $e$  ismeretlen zaj.

A naïve megoldás:  $x = A^{-1}b$ .

Ha  $A = USV^T$  (szinguláris felbontás), akkor

$$x = VS^{-1}U^T b = \sum_{i=1}^n \frac{u_i^T b}{\sigma_i} v_i$$

kis  $\sigma_i$  értékekkel való osztás  $\rightarrow$  nagy hibák


**Filtering:**

$$x = \sum_{i=1}^n \Phi_i \frac{u_i^T b}{\sigma_i} v_i,$$

ahol

$$\Phi_i \approx \begin{cases} 1 & \text{nagy } \sigma_i\text{-re,} \\ 0 & \text{kicsi } \sigma_i\text{-re} \end{cases}$$

Egy  $A \in \mathbb{R}^{1600 \times 1600}$  mátrix szinguláris értékei, ahol az  $A$  a főátlójában és az 5-5 szomszédos mellékátlójában  $\frac{1}{11}$ -ek állnak, a többi eleme 0.



Az  $A$  szinguláris felbontásában szereplő  $V$  mátrix néhány oszlopvektora (a  $V(:, i)$  vektor néhány  $i$  esetén).

$i=1$



$i=5$



$i=10$



$i=100$



$i=200$



$i=300$



$i=500$




$i=1000$



$i=1600$



`reshape(V(:,i),[40,40])` néhány  $i$  esetén



## Csonkított SVD:

$$x = \sum_{i=1}^k \frac{u_i^T b}{\sigma_i} v_i$$

ahol  $k < n$ .

## Tikhonov regularizáció:

$$x = \sum_{i=1}^n \frac{\sigma_i^2}{\sigma_i^2 + \alpha^2} \frac{u_i^T b}{\sigma_i} v_i,$$

ami a

$$\min_x (\|Ax - b\|^2 + \alpha^2 \|x\|^2)$$

feladat megoldása.



Az eredeti kép



Az eredeti kép megszorozva egy olyan  $A$  mátrixszal, melynek a főátlójában és az  $5 \times 5$  szomszédos mellékátlójában  $\frac{1}{11}$ -ek állnak, a többi eleme 0.



Az előző kép + egy 0 várható értékű, 0.01 szórású normális eloszlásból származó zaj.



A naïve megoldás.



Egy megoldás Tikhonov-regularizációval.

# Legkisebb négyzetek alkalmazása

## Példa.

Egy műhold pályájára a következő adatokat mértük a  $(r, \varphi)$  polárkoordináta rendszerben

$\varphi_i$	48°	88°	150°	221°	247°	311°	359°
$r_i$	4.32	2.05	1.18	1.26	1.52	4.25	9.98

Kepler törvénye szerint

$$r = \frac{p}{1 - e \cdot \cos \varphi},$$

ahol  $p$  és  $e$  paraméterek. Becsüljük meg a paraméterek értékét.

## 1. megoldás, linearizáció.

Az  $r = \frac{p}{1-e \cdot \cos \varphi}$  egyenlet helyett tekintsük az

$$\frac{1}{r} = \frac{1}{p} - \frac{e}{p} \cos \varphi$$

egyenletet.

Keressük azt a

$$F(\varphi) = a + b \cdot \cos \varphi$$


modellt, mely illeszkedik a  $\left(\varphi_i, \frac{1}{r_i}\right)$  adatokra. (vagy a  $\left(\cos \varphi_i, \frac{1}{r_i}\right)$  adatokra illeszkedő egyenest.)

$$A = \begin{pmatrix} 1 & \cos(44^\circ) \\ 1 & \cos(88^\circ) \\ 1 & \cos(150^\circ) \\ 1 & \cos(221^\circ) \\ 1 & \cos(247^\circ) \\ 1 & \cos(311^\circ) \\ 1 & \cos(359^\circ) \end{pmatrix}, \quad y = \begin{pmatrix} 1/4.32 \\ 1/2.05 \\ 1/1.18 \\ 1/1.26 \\ 1/1.52 \\ 1/4.25 \\ 1/9.98 \end{pmatrix}, \quad x = \begin{pmatrix} a \\ b \end{pmatrix},$$

ahol az  $A^T A x = A^T y$  normálegyenlet:

$$\begin{pmatrix} 7 & 0.3485 \\ 0.3485 & 3.3513 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 3.3538 \\ -1.1635 \end{pmatrix}.$$

A megoldás:  $a = 0.4990$  és  $b = -0.3991$ . Felhasználva, hogy  $a = 1/p$  és  $b = e/p$  kapjuk, hogy  $p = 2.0041$ ,  $e = 0.7997$ .



## 2. megoldás, nemlineáris legkisebb négyzetek

Legyen

$$g(p, e) = \begin{pmatrix} \frac{p}{1-e \cdot \cos \varphi_1} - r_1 \\ \vdots \\ \frac{p}{1-e \cdot \cos \varphi_m} - r_m \end{pmatrix}$$

Keresett

$$\min_{(p,e)} \frac{1}{2} \|g(p, e)\|^2$$

Az lsqnonlin Matlab-függvény segítségével:

$$p = 2.0121 \quad e = 0.7986$$

